PERBANDINGAN MODEL *DECISION TREE* DAN *RANDOM FOREST* DALAM MEMPREDIKSI KESESUAIAN LAHAN TANAMAN KELAPA SAWIT

SKRIPSI



Disusun Oleh :

FERDY HARDIANSYAH
220203012

PROGRAM STUDI SISTEM DAN TEKNOLOGI INFORMASI
FAKULTAS SAINS DAN TEKNOLOGI
INSTITUT TEKNOLOGI SAWIT INDONESIA
MEDAN
2026

PERBANDINGAN MODEL *DECISION TREE* DAN *RANDOM FOREST* DALAM MEMPREDIKSI KESESUAIAN LAHAN TANAMAN KELAPA SAWIT

SKRIPSI

Sebagai salah satu syarat untuk memperoleh gelar Sarjana Komputer pada Program Studi Sistem dan Teknologi Informasi

Disusun Oleh :

FERDY HARDIANSYAH
220203012

PROGRAM STUDI SISTEM DAN TEKNOLOGI INFORMASI
FAKULTAS SAINS DAN TEKNOLOGI
INSTITUT TEKNOLOGI SAWIT INDONESIA
MEDAN
2026

LEMBAR PENGESAHAN SKRIPSI

PERBANDINGAN MODEL *DECISION TREE* DAN *RANDOM FOREST* DALAM MEMPREDIKSI KESESUAIAN LAHAN TANAMAN KELAPA SAWIT

FERDY HARDIANSYAH
220203012

Disetujui oleh

Pembimbing:

Ratu Mutiara Siregar, S.Kom., M.Kom. _____
NIDN. 0106049403

Diketahui oleh

Kepala Program Studi Sistem Dan Teknologi Informasi:

Ritna Wahyuni, S.Kom., M.Kom.
NIDN. 0123099601 _____

ABSTRAK

Ferdy Hardiansyah, Perbandingan Model *Decision Tree* Dan *Random Forest* Dalam Memprediksi Kesesuaian Lahan Tanaman Kelapa Sawit. Dibimbing oleh Ibu Ratu Mutiara Siregar, S.Kom., M.kom.

Pulau Sumatra merupakan salah satu wilayah utama pengembangan perkebunan kelapa sawit di Indonesia yang memiliki karakteristik biofisik beragam, meliputi variasi topografi, iklim, dan sifat tanah. Pemanfaatan lahan yang tidak sesuai dengan karakteristik biofisiknya dapat menurunkan produktivitas tanaman serta meningkatkan risiko degradasi lingkungan. Penelitian ini bertujuan untuk membangun dan membandingkan model prediksi kesesuaian lahan kelapa sawit menggunakan algoritma *Decision Tree* dan *Random Forest* berbasis data spasial biofisik di Pulau Sumatra. Variabel yang digunakan meliputi kemiringan lereng, curah hujan, suhu, pH tanah, tekstur tanah, kedalaman tanah, dan tutupan lahan. Kelas kesesuaian lahan ditentukan berdasarkan kerangka evaluasi lahan FAO dan Petunjuk Teknis Klasifikasi Tanah Nasional (BBSDLP, 2016) yang terdiri atas kelas S1 (sangat sesuai), S2 (cukup sesuai), S3 (sesuai marginal), dan N (tidak sesuai). Metode penelitian meliputi pengumpulan data sekunder, pengolahan data spasial menggunakan Geographic Information System (GIS), pembentukan dataset, pembagian data latih dan data uji, serta validasi menggunakan *K-Fold Cross Validation*. Hasil penelitian menunjukkan bahwa model *Decision Tree* memperoleh nilai akurasi sebesar 88.30%, sedangkan *Random Forest* memperoleh nilai akurasi sebesar 97.99%. Berdasarkan hasil evaluasi menggunakan *accuracy*, confusion matrix, classification report, dan cross validation, algoritma *Random Forest* menunjukkan performa terbaik dalam memprediksi kesesuaian lahan kelapa sawit. Penelitian ini menunjukkan bahwa pendekatan *Machine Learning* mampu digunakan untuk memodelkan kesesuaian lahan secara efektif serta menghasilkan informasi spasial yang dapat mendukung perencanaan dan pengelolaan lahan kelapa sawit yang lebih objektif dan berkelanjutan di Pulau Sumatra.

Kata Kunci: Kesesuaian_lahan, Kelapa_sawit, *Decision_Tree, Random_Forest, Machine_Learning*

ABSTRACT

Ferdy Hardiansyah, *Comparison of Decision Tree and Random Forest Models in Predicting Oil Palm Land Suitability*. *Supervised by Mrs.* Ratu Mutiara Siregar, S.Kom., M.kom.

Sumatra Island is one of the major oil palm plantation regions in Indonesia, characterized by diverse biophysical conditions, including variations in topography, climate, and soil properties. Land utilization that does not consider biophysical suitability may reduce crop productivity and increase the risk of environmental degradation. This study aims to develop and compare oil palm land suitability prediction models using Decision Tree and Random Forest algorithms based on biophysical spatial data across Sumatra Island. The variables used in this study include slope, Rainfall, temperature, soil pH, soil texture, soil depth, and land cover. Land suitability classes were determined based on the FAO land evaluation framework and the National Soil Classification Technical Guidelines (BBSDLP, 2016), which classify land into four suitability classes: S1 (highly suitable), S2 (moderately suitable), S3 (marginally suitable), and N (not suitable). The research methodology consisted of secondary data collection, spatial data processing using Geographic Information Systems (GIS), dataset construction, train–test data partitioning, and model validation using K-Fold Cross Validation. The results showed that the Decision Tree model achieved an accuracy of 88.30%, while the Random Forest model achieved an accuracy of 97.99%. Based on evaluations using accuracy, confusion matrix, classification report, and cross-validation, the Random Forest algorithm demonstrated superior performance in predicting oil palm land suitability. These findings indicate that Machine Learning approaches can effectively model land suitability and provide spatial information to Support more objective and sustainable oil palm land-use planning and management across Sumatra Island.

Keywords: Land_suitability, Oil_palm, Decision_Tree, Random_Forest, Machine_Learning

KATA PENGANTAR

Puji dan syukur penulis panjatkan ke hadirat Tuhan Yang Maha Esa atas segala rahmat, kasih karunia, dan penyertaan-Nya sehingga Skripsi ini dapat disusun dengan baik. Penulis juga mengucapkan terima kasih yang sebesar-besarnya kepada kedua orang tua tercinta yang senantiasa menjadi sumber kekuatan, harapan, dan semangat bagi penulis. Doa yang tak pernah putus, kasih sayang yang tulus, serta dukungan yang tanpa henti menjadi pengiring setiap langkah penulis hingga mampu menyelesaikan skripsi ini. Penyusunan Skripsi ini tidak terlepas dari bantuan, bimbingan, serta dukungan dari berbagai pihak. Oleh karena itu, penulis dengan tulus menyampaikan ucapan terima kasih kepada:

1. Bapak Dr. Pujianto, S.E., M.M selaku Rektor Institut Teknologi Sawit Indonesia.
2. Bapak Aulia Juanda Djaingsastro, S.Si., M.Si selaku Dekan Fakultas Sains dan Teknologi.
3. Ibu Ritna Wahyuni, S.Kom., M.Kom selaku Kepala Program Studi Sistem dan Teknologi Informasi.
4. Ibu Ratu Mutiara Siregar, S.Kom., M.Kom., selaku Dosen Pembimbing yang telah dengan tulus meluangkan waktu, tenaga, dan pemikiran dalam membimbing penulis. Setiap arahan, koreksi, dan nasihat yang diberikan menjadi cahaya penuntun di tengah berbagai tantangan penyusunan penelitian ini, sehingga penulis dapat terus melangkah hingga menyelesaikan Skripsi ini.
5. Badan Pengelola Dana Perkebunan Kelapa Sawit (BPDP) atas dukungan pendanaan melalui program beasiswa yang diberikan kepada penulis.
6. Abang, kakak, serta kedua adik tercinta yang selalu hadir sebagai tempat pulang, sumber semangat, dan penyemangat dalam setiap langkah perjalanan penulis. Terima kasih atas doa yang tak pernah putus, dukungan yang tak pernah surut, serta kasih sayang yang senantiasa menguatkan di tengah berbagai

tantangan. Kehadiran kalian menjadi salah satu alasan bagi penulis untuk terus berjuang dan bertahan hingga akhirnya mampu menyelesaikan Skripsi ini.

7. Rekan-rekan penghuni kontrakan Imor & Raul, khususnya Bayu, Nabil, Aycel, Agung, dan Nadeak, yang telah menemani penulis sejak awal menapaki dunia perkuliahan. Terima kasih atas setiap cerita, tawa, diskusi, bantuan, dan kebersamaan yang terukir selama perjalanan ini. Kehadiran kalian bukan hanya menjadi teman seperjuangan, tetapi juga keluarga kedua yang memberikan dukungan dan kekuatan hingga penulis dapat menyelesaikan tugas akhir ini.
8. Teman-teman kelas STI A 2022 yang telah berjalan bersama dalam mengarungi perjalanan perkuliahan. Terima kasih atas setiap tawa yang menghangatkan hari, setiap diskusi yang memperluas wawasan, serta setiap dukungan yang menguatkan langkah di tengah berbagai tantangan akademik. Kebersamaan yang terjalin selama ini bukan sekadar menjadi bagian dari masa studi, melainkan juga menjadi rangkaian kenangan indah yang akan senantiasa tersimpan dan dikenang dalam perjalanan hidup penulis.
9. Teman-teman PKLForAight, yang telah menjadi keluarga sementara dalam perjalanan Praktik Kerja Lapangan. Terima kasih atas setiap canda, cerita, kerja sama, serta semangat yang saling diberikan selama masa PKL. Kebersamaan yang terjalin tidak hanya menghadirkan pengalaman dan pembelajaran yang berharga, tetapi juga meninggalkan jejak kenangan yang akan selalu tersimpan dalam ingatan penulis sebagai bagian indah dari perjalanan menempuh pendidikan.

Penulis menyadari bahwa Skripsi ini masih memiliki keterbatasan. Oleh karena itu, kritik dan saran yang membangun sangat diharapkan demi penyempurnaan penelitian selanjutnya. Besar harapan penulis agar proposal ini dapat memberikan manfaat serta menjadi salah satu kontribusi dalam pengembangan teknologi informasi di sektor perkebunan kelapa sawit, khususnya di lingkungan Institut Teknologi Sawit Indonesia.

Akhir kata, penulis mengucapkan terima kasih dan semoga proposal penelitian ini dapat bermanfaat serta menambah wawasan bagi para pembaca.

Medan, 4 Januari 2025

FERDY HARDIANSYAH

DAFTAR ISI

HALAMAN JUDUL ii

LEMBAR PENGESAHAN SKRIPSI ..... **iii**

ABSTRAK ..... **iv**

ABSTRACT ..... **v**

KATA PENGANTAR ..... **vi**

DAFTAR ISI ..... **ix**

DAFTAR TABEL ..... **xii**

DAFTAR GAMBAR ..... **xiii**

BAB I PENDAHULUAN **14**

1.1 Latar Belakang 14

1.2 Perumusan Masalah 16

1.3 Batasan Masalah 16

1.4 Tujuan Penelitian 17

1.5 Manfaat penelitian 18

BAB II LANDASAN TEORI **19**

2.1 Kesesuian Lahan 19

2.2 Kelapa Sawit 20

2.3 SIG dan Analisis Spasial dalam Evaluasi Lahan 22

2.4 *Decision Tree* 23

2.5 *Random Forest* 25

2.6 Penelitian terdahulu 28

BAB III METODE PENELITIAN **31**

3.1 Tahapan penelitian 31

3.2 Pengumpulan Data 32
3.2.1 Waktu dan Tempat Penelitian 32
3.2.2 Jenis dan Sumber Data 32
3.2.3 Penentuan Kelas Kesesuaian Lahan (S1, S2, S3, N) 34
3.2.4 Metode Pengumpulan Data 36
3.2.5 Pengolahan Awal Data (*Pre-processing*) 38
3.2.6 Hasil Pengumpulan Data 40
3.3 Metode Penelitian 41
3.4 Validasi Model 42
3.4.1 Pembagian Dataset (Train–Test Split) 42
3.4.2 Validasi Silang K-Fold (*K-Fold Cross-Validation*) 43
3.4.3 Metrik Evaluasi Model 43
3.4.4 Pemilihan Model Terbaik 46
3.5 Rancangan penelitian 46
3.5.1 Pemodelan UML 47
3.5.2 Rancangan *User* Interface 54
3.6 Jadwal penelitian 57

BAB IV HASIL DAN PEMBAHASAN 59

4.1 Hasil Pengolahan Data 59
4.1.1 Contoh Dataset Hasil Ekstraksi 59
4.2 Ekstraksi dan Pembentukan Dataset 60
4.3 Pembersihan Data (Data Cleaning) 61
4.4 Penentuan Kelas Kesesuaian Lahan 61
4.4.1 Distribusi Kelas Kesesuaian Lahan 62
4.5 Hasil Pemodelan *Machine Learning* 63
4.5.1 *Decision Tree* 64
4.5.2 *Random Forest* 64
4.6 Evaluasi Model 64

4.6.1 *Accuracy* 65
4.6.2 Confusion Matrix 66
4.6.3 Classification Report 67
4.6.4 Metrik Evaluasi Keseluruhan 69
4.6.5 Cross Validation 69
4.7 Analisis Feature Importance 70
4.8 Implementasi Sistem Visualisasi Berbasis Web 72
4.8.1 Dashboard Utama 72
4.8.2 Halaman Evaluasi *Decision Tree* 73
4.8.3 Halaman Evaluasi *Random Forest* 75
4.8.4 Halaman Perbandingan Model 76
4.9 Visualisasi Spasial Kesesuaian Lahan 78
4.10 Keterbatasan Penelitian 80

BAB V KESIMPULAN DAN SARAN 81

5.1 Kesimpulan 81
5.2 Saran 82

DAFTAR PUSTAKA 84

BIOGRAFI PENULIS 88

DAFTAR TABEL

1 Variabel Kesesuaian Lahan Sederhana 20
2 Perbandingan Penelitian Terdahulu dan Penelitian Ini 30
3 Data Spasial 33
4 Kriteria Kesesuaian Lahan Kelapa Sawit (*Elaeis guineensis Jacq.*) 35
5 Struktur Dataset 40
6 Jadwal Penelitian 58
7 Contoh Data Hasil Ekstraksi Raster untuk Pemodelan kesesuaian Lahan 59
8 *Accuracy* 65
9 *Classification report Decision Tree* 67
10 *Classification report Random Forest* 68
11 Perbandingan Metrik Evaluasi 69
12 Hasil *K-Fold Cross Validation* 69
13 *Ranking Feature Importance* 71
14 Sebaran Kelas Kesesuaian Lahan Kelapa Sawit di Pulau Sumatra 79

DAFTAR GAMBAR

1 Tahapan Penelitian 31
2 Tahap *Preprocessing* 38
3 *Usecase Diagram* 47
4 *Activity Diagram* 49
5 *Class Diagram* 50
6 Sequence Diagram 53
7 Tampilan Dashboard Utama 54
8 Tampilan Peta Hasil *Decision Tree* 55
9 Tampilan Peta Hasil *Random Forest* 56
10 Tampilan Grafik Perbandingan Model 57
11 Flowchart Implementasi Pemodelan *Machine Learning* 63
12 *Confusion Matrix Decision Tree* 66
13 *Confusion Matrix Random Forest* 66
14 Tampilan *Feature Importance* 71
15 Dashboard Utama Kesesuaian Lahan 72
16 Halaman Evaluasi *Decision Tree* 74
17 Halaman Evaluasi *Random Forest* 75
18 Halaman Perbandingan Model 77
29 Peta Kesesuaian Lahan Kelapa Sawit 78

BAB I
PENDAHULUAN

1.1 Latar Belakang

Pulau Sumatra merupakan wilayah dengan karakteristik biofisik yang kompleks, ditandai oleh variasi topografi, kondisi tanah yang beragam, serta intensitas curah hujan yang relatif tinggi. Karakteristik tersebut menjadikan Sumatra sebagai kawasan yang sensitif terhadap perubahan penggunaan lahan dalam skala regional. Pada akhir tahun 2025, sejumlah provinsi di Pulau Sumatra mengalami bencana hidrometeorologis seperti banjir dan tanah longsor yang menimbulkan korban jiwa, kerusakan infrastruktur, serta gangguan aktivitas masyarakat (Fransiska & Widianto. 2025). Peristiwa tersebut menunjukkan bahwa pemanfaatan lahan yang tidak selaras dengan karakteristik fisik wilayah dapat berkontribusi terhadap munculnya dampak lingkungan yang signifikan.

Perubahan penggunaan lahan yang tidak mempertimbangkan prinsip biofisik wilayah merupakan salah satu faktor yang memengaruhi kualitas dan stabilitas lingkungan. Alih fungsi hutan, berkurangnya vegetasi penutup, serta pembukaan lahan pada daerah berkelerengan berpotensi menurunkan kemampuan tanah dalam mengatur limpasan permukaan dan menjaga kestabilan lereng. Kajian ilmiah menunjukkan bahwa degradasi tutupan lahan berkaitan dengan peningkatan erosi dan sedimentasi, terutama pada wilayah dengan kondisi topografi yang kompleks (Putra et al. 2025). Kondisi ini menegaskan pentingnya evaluasi kesesuaian lahan agar pemanfaatan ruang dapat dilakukan sesuai dengan kemampuan dan karakteristik fisiknya.

Selain aspek lingkungan, Pulau Sumatra juga merupakan pusat pengembangan perkebunan kelapa sawit yang memiliki peran strategis dalam perekonomian nasional. Kebutuhan lahan untuk ekspansi perkebunan kelapa sawit sering kali tidak diiringi dengan penilaian kesesuaian lahan yang komprehensif. Padahal, pertumbuhan dan

produktivitas tanaman kelapa sawit sangat dipengaruhi oleh faktor-faktor biofisik seperti jenis tanah, kemiringan lereng, kondisi drainase, dan ketersediaan air. Pemanfaatan lahan yang tidak sesuai dengan karakteristik tersebut berpotensi menurunkan produktivitas serta menimbulkan tekanan terhadap lingkungan. Oleh karena itu, penilaian kesesuaian lahan berbasis data menjadi aspek penting dalam mendukung pengelolaan perkebunan yang berkelanjutan.

Perkembangan teknologi geospasial dan *Machine Learning* memberikan peluang untuk melakukan penilaian kesesuaian lahan secara lebih objektif dan efisien, khususnya pada wilayah dengan cakupan luas seperti Pulau Sumatra. Algoritma pembelajaran mesin, seperti *Decision Tree* dan *Random Forest*, telah banyak digunakan dalam analisis spasial dan pemodelan biofisik di sektor pertanian karena kemampuannya dalam menangkap hubungan nonlinier antar variabel (Putra et al. 2025). Di sisi lain, penelitian lingkungan menunjukkan bahwa perubahan tutupan lahan dan tekanan ekologis berperan dalam menurunkan kualitas lingkungan sehingga memerlukan pendekatan pemodelan berbasis data untuk memahaminya secara lebih komprehensif (Putra et al. 2025). Namun demikian, sebagian besar penelitian sebelumnya masih berfokus pada penerapan satu algoritma atau dilakukan pada wilayah dengan cakupan yang relatif terbatas.

Berdasarkan tinjauan terhadap penelitian terdahulu, masih terbatas kajian yang secara khusus membandingkan performa algoritma *Decision Tree* dan *Random Forest* dalam memprediksi kesesuaian lahan kelapa sawit berbasis variabel biofisik pada skala regional Pulau Sumatra. Ketiadaan kajian komparatif tersebut menunjukkan adanya celah penelitian yang perlu diisi, khususnya untuk mengetahui algoritma yang memiliki performa lebih baik dalam memodelkan kesesuaian lahan pada wilayah dengan karakteristik biofisik yang kompleks.

Dengan demikian, penelitian ini memiliki urgensi baik secara akademik maupun praktis. Secara akademik, penelitian ini berkontribusi dalam pengembangan penerapan *Machine Learning* untuk pemodelan kesesuaian lahan. Secara praktis, hasil penelitian diharapkan dapat memberikan informasi kesesuaian lahan kelapa sawit yang

lebih akurat dan aplikatif sebagai dasar perencanaan dan pengelolaan lahan yang produktif dan berkelanjutan di Pulau Sumatra.

1.2 Perumusan Masalah

Permasalahan dalam penelitian ini berkaitan dengan kebutuhan akan pemodelan kesesuaian lahan kelapa sawit yang akurat dan berbasis data pada skala regional Pulau Sumatra. Hingga saat ini, informasi kesesuaian lahan yang memanfaatkan variabel biofisik secara komprehensif serta pendekatan *Machine Learning* masih terbatas, khususnya untuk wilayah dengan karakteristik biofisik yang kompleks. Oleh karena itu, diperlukan kajian mengenai bagaimana algoritma *Decision Tree* dan *Random Forest* dapat digunakan untuk memprediksi kelas kesesuaian lahan kelapa sawit, serta bagaimana perbandingan performa kedua algoritma tersebut dalam menghasilkan prediksi yang akurat dan reliabel sebagai dasar perencanaan dan pengelolaan lahan yang berkelanjutan di Pulau Sumatra.

1.3 Batasan Masalah

Penelitian ini dibatasi pada analisis kesesuaian lahan untuk tanaman kelapa sawit dengan cakupan wilayah seluruh Pulau Sumatra sebagai daerah kajian. Fokus penelitian diarahkan pada pemanfaatan variabel biofisik lahan yang relevan terhadap kesesuaian lahan, seperti kemiringan lereng, jenis tanah, curah hujan, dan tutupan lahan, yang diolah dalam bentuk data spasial. Penelitian ini tidak mencakup pembahasan mendalam mengenai aspek sosial-ekonomi, kebijakan pengelolaan perkebunan, maupun faktor kelembagaan lainnya. Penilaian kesesuaian lahan yang digunakan dalam penelitian ini mengacu pada pendekatan deterministik FAO dan Petunjuk Teknis BBSDLP sebagai acuan awal (*baseline*), sehingga hasil pemodelan tidak dimaksudkan untuk menetapkan kriteria kesesuaian lahan baru. Algoritma *Machine Learning* digunakan sebagai pendekatan aproksimatif (*surrogate*) untuk mengevaluasi kemampuan model dalam mempelajari pola hubungan antar variabel

biofisik serta konsistensi spasial kesesuaian lahan pada skala regional. Skala Pulau Sumatra dipilih secara sadar sebagai tantangan metodologis untuk menguji kemampuan model dalam menangkap kompleksitas dan variasi biofisik regional, bukan sebagai klaim generalisasi absolut terhadap seluruh wilayah perkebunan kelapa sawit di Indonesia.

Penelitian ini hanya membandingkan performa dua algoritma pembelajaran mesin, yaitu *Decision Tree* dan *Random Forest*, sehingga tidak mencakup penerapan maupun evaluasi algoritma pembelajaran mesin lainnya. Evaluasi kinerja model difokuskan pada perbandingan performa relatif dan kemampuan prediktif antar algoritma berdasarkan data spasial yang tersedia, tanpa dimaksudkan sebagai validasi absolut. Penelitian ini tidak melakukan survei lapangan secara langsung, melainkan memanfaatkan data sekunder dan data spasial yang bersumber dari lembaga resmi. Aspek kebencanaan seperti banjir dan tanah longsor tidak dimodelkan secara eksplisit dalam pemodelan, melainkan digunakan sebagai konteks pemilihan wilayah kajian dengan karakteristik biofisik yang kompleks. Dengan demikian, ruang lingkup penelitian dibatasi pada pengolahan data biofisik, pemodelan spasial, serta perbandingan performa algoritma dalam konteks kesesuaian lahan kelapa sawit di Pulau Sumatra.

1.4 Tujuan Penelitian

Berdasarkan perumusan masalah, tujuan dari penelitian ini adalah sebagai berikut:

1. Menganalisis karakteristik biofisik lahan yang berkaitan dengan kesesuaian lahan kelapa sawit pada skala regional Pulau Sumatra.
2. Membangun model prediksi kesesuaian lahan kelapa sawit menggunakan algoritma *Decision Tree* dan *Random Forest* berbasis data spasial biofisik di Pulau Sumatra.

3. Mengevaluasi performa prediktif algoritma *Decision Tree* dan *Random Forest* dalam memetakan kelas kesesuaian lahan kelapa sawit berdasarkan metrik evaluasi yang relevan.
4. Membandingkan performa kedua algoritma untuk menentukan model yang memberikan hasil prediksi paling akurat dan stabil sebagai dasar penyediaan informasi kesesuaian lahan kelapa sawit di Pulau Sumatra.

1.5 Manfaat penelitian

Hasil penelitian ini diharapkan memberikan manfaat sebagai berikut:

1. Menghasilkan model prediksi kesesuaian lahan kelapa sawit berbasis data spasial biofisik melalui perbandingan algoritma *Decision Tree* dan *Random Forest*, sehingga menyediakan informasi kesesuaian lahan yang lebih objektif dan terukur sebagai dasar perencanaan penggunaan lahan di Pulau Sumatra.
2. Memberikan dasar analisis berbasis data bagi pengambil keputusan dalam menentukan alokasi lahan perkebunan kelapa sawit, sehingga dapat mengurangi pemanfaatan lahan yang tidak sesuai dengan karakteristik biofisiknya dan mendukung prinsip pengelolaan sumber daya lahan yang berkelanjutan (mendukung SDG 12: Responsible Consumption and Production).
3. Menyajikan peta dan informasi klasifikasi kesesuaian lahan yang dapat dimanfaatkan dalam perencanaan tata ruang dan pengelolaan wilayah, sehingga berkontribusi dalam menjaga kualitas lahan dan keseimbangan ekosistem darat (mendukung SDG 15: Life on Land).
4. Memberikan kontribusi metodologis berupa penerapan dan evaluasi algoritma *Machine Learning* berbasis data spasial biofisik yang dapat dijadikan rujukan bagi penelitian selanjutnya dalam bidang pemodelan kesesuaian lahan dan analisis spasial lingkungan pada skala regional.

BAB II
LANDASAN TEORI

2.1 Kesesuian Lahan

Kesesuaian lahan merupakan tingkat kecocokan suatu satuan lahan untuk penggunaan tertentu berdasarkan kondisi biofisik serta kebutuhan tanaman yang ingin dibudidayakan. Konsep ini pada dasarnya menilai apakah suatu lahan dapat memberikan hasil optimal tanpa menimbulkan kerusakan lingkungan atau memerlukan input perbaikan yang tidak ekonomis. FAO mengklasifikasikan kesesuaian lahan ke dalam empat kelas utama, yaitu S1 (sangat sesuai), S2 (cukup sesuai), S3 (sesuai marginal), dan N (tidak sesuai), di mana tiap kelas menunjukkan tingkat pembatas yang berbeda terhadap produktivitas lahan (Mgohele et al. 2025)

Penilaian kesesuaian lahan dilakukan melalui analisis berbagai faktor biofisik seperti tekstur tanah, kedalaman perakaran, pH tanah, kemiringan lereng, drainase, curah hujan, suhu, serta kondisi topografi. Faktor-faktor ini berperan sebagai indikator pembatas dalam menentukan kecocokan lahan untuk komoditas tertentu (AbdelRahman et al. 2022). Proses ini dikenal sebagai *matching*, yaitu mencocokkan karakteristik lahan dengan persyaratan tumbuh tanaman sehingga dapat diketahui tingkat kesesuaian secara lebih objektif dan terukur. Di dalam pendekatan modern, analisis ini tidak hanya menggunakan interpretasi manual, tetapi juga mengintegrasikan data spasial dan model kuantitatif untuk meningkatkan akurasi evaluasi lahan (Radočaj & Jurišić. 2022).

Meskipun penilaian kesesuaian lahan secara konseptual dapat dilakukan melalui pendekatan deterministik seperti kerangka FAO, pendekatan tersebut memiliki keterbatasan dalam menangkap hubungan nonlinier serta interaksi kompleks antar variabel biofisik, terutama pada wilayah dengan cakupan spasial yang luas. Oleh karena itu, integrasi pendekatan pemodelan berbasis data, termasuk penggunaan algoritma *Machine Learning*, diperlukan untuk mengevaluasi kemampuan model

dalam mempelajari pola hubungan antar variabel biofisik secara lebih adaptif serta meningkatkan kemampuan generalisasi hasil pemodelan pada skala regional.

Dalam konteks wilayah Pulau Sumatra, variabel biofisik seperti kemiringan lereng, kondisi drainase, dan curah hujan memiliki peran penting dalam menentukan potensi pertumbuhan dan produktivitas tanaman kelapa sawit. Kompleksitas karakteristik fisik wilayah tersebut menuntut adanya analisis kesesuaian lahan yang mempertimbangkan variasi spasial secara menyeluruh agar pemanfaatan lahan dapat dilakukan sesuai dengan kemampuan dan karakteristik biofisiknya.

Tabel berikut memberikan gambaran penyederhanaan variabel kesesuaian lahan kelapa sawit berdasarkan kerangka FAO yang telah banyak digunakan dalam penelitian evaluasi lahan sawit(Alraniri, 2023; Goenadi et al. 2021)

Tabel 1 Variabel Kesesuaian Lahan Sederhana

Persyaratan penggunaan/karakteristik lahan	**Kelas kesesuaian lahan S1**
Temperatur rata-rata tahunan (°C)	24–28
Curah hujan tahuan (mm)	1.700–3.000
Jumlah bulan kering (<100 mm)	<1
Tekstur tanah	halus–sedang
Kedalaman tanah (cm)	>100
pH tanah	5.0–6.5
Kemiringan lereng (%)	<8

Variabel ini kemudian digunakan sebagai dasar proses *matching* antara karakteristik biofisik lahan dan persyaratan tumbuh kelapa sawit untuk menentukan kelas kesesuaian S1, S2, S3, atau N.

2.2 Kelapa Sawit

Tanaman kelapa sawit *(Elaeis guineensis)* berasal dari hutan hujan tropis Afrika Barat yang terletak di antara 15°LU dan 15°LS. Tanaman ini pertama kali dibudidayakan di Asia Tenggara pada tahun 1848 di Kebun Raya Bogor, Indonesia

(Nambiappan et al. 2018, dalam Abubakar et al. 2023).Secara agroklimat, kelapa sawit tumbuh optimal pada curah hujan tahunan antara 1.700–2.875 mm, suhu rata-rata tahunan lebih dari 22°C, dan pada ketinggian di bawah 1.500 m dpl. Tanah yang sesuai memiliki tekstur lempung berpasir hingga lempung liat, serta pH tanah berkisar 4–8 dengan drainase baik (Paterson et al. 2013; Corley & Tinker. 2003, dalam Abubakar et al. 2022).

Berdasarkan klasifikasi kesesuaian lahan FAO yang diadaptasi oleh Abubakar et al. (2022) wilayah dengan kemiringan 0–8° dan defisit air tahunan <150 mm dikategorikan sebagai sangat sesuai (S1), sedangkan kemiringan lebih dari 50° atau defisit air >400 mm tergolong tidak sesuai (N). Faktor biofisik seperti pH tanah, curah hujan, suhu, lereng, dan ketersediaan air tanah terbukti memiliki pengaruh signifikan terhadap produktivitas kelapa sawit. Suhu yang terlalu tinggi, khususnya di atas 35°C, dapat menurunkan efisiensi fotosintesis, sedangkan ketersediaan radiasi minimal sebesar 16–17 MJ m^{-2} $hari^{-1}$ diperlukan untuk pertumbuhan optimal (Abu Bakar et al. 2023).

Secara spasial, penelitian menggunakan pendekatan GIS menunjukkan bahwa curah hujan tahunan merupakan parameter paling dominan dalam menentukan kesesuaian lahan untuk kelapa sawit, diikuti oleh jumlah bulan kering, suhu, kemiringan lereng, dan tekstur tanah (Abubakar et al. 2023). Kondisi ini sangat relevan dengan konteks Pulau Sumatra yang memiliki variasi topografi, tingkat curah hujan tinggi, serta wilayah-wilayah yang rentan terhadap banjir dan tanah longsor. Faktor drainase tanah dan kemiringan lereng—yang merupakan komponen penting dalam penilaian kesesuaian lahan kelapa sawit—juga merupakan variabel yang berperan langsung dalam menentukan tingkat kerentanan suatu wilayah terhadap bencana hidrometeorologis.

Dengan demikian, karakteristik biofisik tanaman kelapa sawit bukan hanya menentukan produktivitas dan kesesuaian lahan, tetapi juga berkaitan erat dengan potensi risiko lingkungan apabila penanaman dilakukan pada area yang tidak sesuai atau pada lahan dengan kerentanan tinggi terhadap banjir dan tanah longsor. Hal ini

menjadi landasan penting dalam pemodelan kesesuaian lahan pada skala Pulau Sumatra.

2.3 SIG dan Analisis Spasial dalam Evaluasi Lahan

Sistem Informasi Geografis (SIG) merupakan alat utama dalam evaluasi kesesuaian lahan karena mampu mengintegrasikan berbagai parameter biofisik seperti topografi, hidrologi, dan karakteristik tanah ke dalam satu platform analisis berbasis peta. Menurut Ahuchaogu udo Emmanuel U et al. (2020), SIG memungkinkan pengolahan dan interpretasi data spasial secara komprehensif melalui teknik overlay, interpolasi, dan analisis tematik, sehingga menghasilkan peta kesesuaian lahan yang lebih akurat dan informatif. Lebih lanjut, integrasi data topografi dalam SIG terbukti berperan penting dalam mengidentifikasi faktor pembatas seperti kemiringan lereng, elevasi, dan pola drainase. Berdasarkan penelitian (Ifeanyi et al. 2024), analisis spasial berbasis DEM *(Digital Elevation Model)* membantu mengidentifikasi area rawan erosi dan wilayah yang kurang ideal untuk budidaya berdasarkan perbedaan elevasi dan gradient lereng.

Selain itu, penerapan geospatial technology dalam evaluasi lahan semakin berkembang dengan memadukan metode *multi-criteria analysis* (MCA) serta teknik *weighted overlay*. Dalam studi Moisa et al. (2023), parameter tanah seperti rasio kelembapan, tekstur tanah, pH, dan ketersediaan air dievaluasi secara spasial untuk menghasilkan peta kesesuaian lahan yang terklasifikasi ke dalam kategori sangat sesuai hingga tidak sesuai. Dengan demikian, SIG bukan hanya berfungsi sebagai alat pemetaan, tetapi juga sebagai sistem analisis yang memungkinkan integrasi multi-layer dari data lingkungan, mendukung pengambilan keputusan penggunaan lahan berbasis bukti, dan memberikan visualisasi spasial yang mudah diinterpretasikan untuk perencanaan budidaya tanaman apa pun, termasuk kelapa sawit.

2.4 *Decision Tree*

Decision Tree adalah algoritma pembelajaran mesin yang bekerja dengan membagi data menjadi beberapa cabang berdasarkan atribut paling berpengaruh terhadap target. Proses pembentukan pohon dilakukan secara rekursif menggunakan pendekatan *top-down divide and conquer*, hingga setiap cabang mewakili keputusan akhir (Gajowniczek & Ząbkowski, 2021).Pemilihan atribut terbaik dilakukan menggunakan ukuran ketidakmurnian seperti *Information Gain, Gain Ratio*, atau *Gini Index*. Atribut dengan nilai informasi tertinggi menjadi dasar pembagian data karena paling efektif membedakan kelas (Prasetiyowati et al. 2021). Namun, metode ini dapat menimbulkan *overfitting* jika data terlalu kompleks. Untuk mengurangi hal tersebut, digunakan seleksi fitur berbasis *information gain* agar model lebih akurat dan tidak bias terhadap atribut tertentu (Oktavianti et al. 2023).

Ukuran ketidakmurnian tersebut dapat dihitung menggunakan rumus berikut:

1. *Entropy*

Rumus :

$$Entropy(S) = \sum_{i=1}^{n} p_i \, log_2(p_i) \qquad (1)$$

Keterangan:

$Entropy(S)$	:	ukuran tingkat ketidakpastian atau ketidakteraturan data dalam suatu himpunan data S.
S	:	himpunan data (dataset) yang sedang dianalisis.
n	:	jumlah kelas dalam dataset
p_i	:	proporsi atau probabilitas data pada kelas ke-i.
$\log_2$	:	logaritma basis 2.

2. *Information Gain*

Rumus :

$$Gain(S, A) = Entropy(S) - \sum_{v \in Values(A)} \frac{|S_v|}{|S|} Entropy(S_v) \quad (2)$$

Keterangan:

Gain(S, A)	:	nilai information gain dari atribut A terhadap dataset S.
Entropy(S)	:	entropy awal dataset sebelum dilakukan pemisahan.
A	:	atribut yang digunakan untuk membagi data.
Values(A)	:	himpunan nilai unik dari atribut A.
S_v	:	subset data hasil pemisahan berdasarkan nilai v dari atribut A.
$\|S_v\|$	:	jumlah data pada subset Sv.
$\|S\|$	:	jumlah total data dalam dataset.

3. *Gini Index*

Rumus :

$$Gini(S) = 1 - \sum_{i=1}^{n} p_i^2 \quad (3)$$

Keterangan :

Gini(S)	:	ukuran tingkat ketidakmurnian (*impurity*) data pada dataset S.
p_i	:	proporsi data pada kelas ke-iii.
n	:	jumlah kelas dalam dataset.

Rumus-rumus tersebut digunakan untuk menentukan atribut mana yang menghasilkan pembagian data paling bersih (*pure*). Nilai entropy atau gini yang rendah menunjukkan bahwa node tersebut lebih homogen, sedangkan nilai Information Gain yang tinggi menunjukkan bahwa atribut tersebut lebih baik dalam memisahkan kelas target.

Penelitian modern juga mengembangkan variasi *Decision Tree* seperti penggunaan fungsi entropi lain (Renyi, Tsallis, Sharma-Mittal, dan Kapur) untuk

meningkatkan fleksibilitas pemilihan atribut, serta pendekatan *Bayesian Decision Tree* yang lebih stabil terhadap *noise* (Gajowniczek & Ząbkowski. 2021). Dalam skala besar, Ma & Zhai. (2023) memperkenalkan metode *unbalanced cut points* untuk mempercepat pemrosesan data kontinu tanpa mengurangi akurasi.

Dalam konteks penelitian ini, *Decision Tree* digunakan untuk menganalisis data spasial (seperti ketinggian, curah hujan, jenis tanah, dan kemiringan) guna menentukan tingkat kesesuaian lahan kelapa sawit. Keunggulan utama metode ini adalah kemampuannya menghasilkan model yang mudah dipahami dan divisualisasikan, serta dapat menangani data numerik maupun kategorikal. Namun, kelemahannya terletak pada kecenderungan mengalami *overfitting* dan sensitivitas terhadap *noise*. Oleh karena itu, penelitian ini juga membandingkan kinerjanya dengan *Random Forest*, yang dikembangkan untuk meningkatkan stabilitas dan akurasi model (Nuti et al. 2021; Oktavianti et al. 2023).

2.5 *Random Forest*

Random Forest merupakan salah satu metode *ensemble learning* yang bekerja dengan membangun banyak pohon keputusan secara acak dan menggabungkan hasilnya melalui proses *voting* atau rata-rata. Teknik ini didasarkan pada prinsip *bagging* (bootstrap aggregating) yang dikembangkan oleh (Breiman 2001, dalam Mushagalusa et al. 2024) di mana setiap pohon dilatih dari subset data yang berbeda untuk mengurangi variansi dan mencegah *overfitting*. Proses pembentukan model *Random Forest* dapat dijelaskan melalui beberapa formula dasar sebagai berikut:

1. Bootstrap Sampling

Rumus :

$$D_b = \{(x_i, y_i)\}_{i=1}^{m}, \qquad x_i \sim D \tag{4}$$

Keterangan:

D_b : dataset bootstrap ke-b yang digunakan untuk membangun satu pohon keputusan.

(x_i, y_i) : pasangan data, dengan x_i sebagai vektor fitur dan y_i sebagai label kelas atau nilai target.

m : jumlah data dalam satu dataset bootstrap.

D : dataset asli

$x_i \sim D$: data diambil secara acak dengan pengembalian (*sampling with replacement*) dari dataset asli D.

2. Voting Mayoritas untuk Klasifikasi

Rumus :

$$\hat{y} = \text{mode}(\{h_b(x)\}_{b=1}^{B}) \quad (5)$$

Keterangan:

$\hat{y}$: hasil prediksi akhir model *Random Forest*.

$h_b(x)$: hasil prediksi dari pohon keputusan ke-b terhadap data x.

B : jumlah total pohon keputusan dalam *Random Forest*.

mode(·) : nilai kelas yang paling sering muncul (*voting mayoritas*).

3. Rata-rata Prediksi untuk Regresi

Rumus :

$$\hat{y} = \frac{1}{B}\sum_{b=1}^{B} h_b(x) \quad (6)$$

Keterangan:

$\hat{y}$: nilai prediksi akhir untuk regresi.

$h_b(x)$: nilai prediksi dari pohon keputusan ke-b.

B : jumlah pohon dalam *Random Forest*.

Setiap pohon dalam *Random Forest* dibentuk dengan memilih sejumlah variabel prediktor secara acak pada tiap percabangan (*random feature selection*), yang membuat setiap pohon relatif tidak berkorelasi satu sama lain. Proses ini menjadikan model lebih stabil dan mampu menangani hubungan nonlinier serta variabel dalam jumlah besar tanpa memerlukan asumsi distribusi data yang ketat (Fulazzaky et al. 2024).

Keunggulan utama *Random Forest* adalah kemampuannya dalam mengurangi *overfitting* dan meningkatkan akurasi prediksi dibandingkan model tunggal seperti *Decision Tree*. Selain itu, metode ini mampu menangani data kompleks, termasuk data dengan ketidakseimbangan kelas maupun data spasial yang memiliki hubungan antarvariabel yang kuat (Fulazzaky et al. 2024; Mushagalusa et al. 2024).Dalam bidang pertanian dan penginderaan jauh, *Random Forest* sering digunakan karena mampu menggabungkan berbagai jenis data seperti citra satelit, model elevasi digital, dan data lingkungan. Ibrahim. (2023) membuktikan bahwa penggunaan *Random Forest* dengan data Sentinel-1, Sentinel-2, dan SRTM dapat meningkatkan akurasi klasifikasi tutupan lahan hingga 89,1%, menunjukkan efektivitas algoritma ini dalam memproses data spasial berskala besar .

Selain itu, penelitian Fulazzaky et al. (2024) menunjukkan bahwa variasi *Balanced Random Forest (BRF)* mampu meningkatkan performa model pada dataset yang tidak seimbang, dengan tetap mempertahankan efisiensi komputasi.Penelitian lain oleh Pradana et al., (2023) juga membuktikan relevansi penggunaan *Random Forest* dalam konteks spasial pertanian di Indonesia. Model ini digunakan untuk memetakan kesesuaian lahan dan kondisi lingkungan menggunakan data spasial seperti curah hujan, jenis tanah, dan suhu permukaan. Hasil penelitian tersebut menunjukkan bahwa *Random Forest* dapat memprediksi kondisi lahan dengan tingkat akurasi tinggi dan sangat berguna dalam perencanaan pengelolaan perkebunan berbasis data.

Dengan kemampuan menggabungkan berbagai tipe data dan menghasilkan model yang stabil serta interpretatif, *Random Forest* sangat relevan digunakan dalam penelitian ini. Algoritma ini dapat memproses data spasial (misalnya ketinggian, kemiringan, curah hujan, dan jenis tanah) untuk menentukan kesesuaian lahan tanaman kelapa sawit secara akurat dan efisien (Ibrahim, 2023; Pradana et al. 2023).

2.6 Penelitian terdahulu

Berbagai penelitian telah dilakukan terkait evaluasi kesesuaian lahan, pemetaan biofisik, serta pemanfaatan teknologi geospasial dan *Machine Learning* dalam analisis penggunaan lahan. Pada perkembangan terbaru, penelitian Nabiollahi et al. (2024) menunjukkan bahwa pemetaan perkebunan kelapa sawit dapat dilakukan secara lebih akurat menggunakan pendekatan *object-based* dan algoritma *Random Forest* berbasis citra Sentinel-1 dan Sentinel-2. Studi tersebut membuktikan bahwa karakteristik spektral dan tekstur citra satelit mampu membedakan tegakan sawit dengan baik, sekaligus memperkirakan kelas umur tanaman secara otomatis. Pendekatan ini menegaskan bahwa *Machine Learning* memiliki kemampuan tinggi dalam mengolah data biofisik yang kompleks, khususnya untuk tanaman kelapa sawit. Temuan tersebut menunjukkan bahwa algoritma *Random Forest* mampu menangkap pola biofisik kompleks dari data spasial, sehingga berpotensi dimanfaatkan tidak hanya untuk pemetaan tutupan lahan, tetapi juga untuk analisis kesesuaian lahan berbasis variabel lingkungan.

Dalam konteks evaluasi biofisik, studi Dwiana Saputri Munika et al. (2024) memetakan sebaran kelas kesesuaian lahan sawit di Kecamatan Tanjung Selor dengan memanfaatkan Sistem Informasi Geografis untuk menggabungkan faktor iklim, tanah, dan topografi. Hasil penelitian menunjukkan variasi kelas kesesuaian dari S1 hingga N, yang menggambarkan peran penting analisis spasial dalam menentukan kelayakan pengembangan sawit. Pendekatan serupa dilakukan oleh Rendana et al. (2022) yang mengevaluasi kesesuaian lahan sawit menggunakan metode matching berbasis SIG pada kawasan dataran tinggi, dan menyoroti peran faktor pembatas seperti ketersediaan air, nutrisi, serta kemampuan kerja lahan terhadap produktivitas tanaman. Namun, pendekatan matching berbasis SIG cenderung bersifat deterministik dan belum mampu menangkap hubungan nonlinier antar variabel biofisik secara optimal. sehingga berpotensi menghasilkan klasifikasi yang kaku pada kondisi lingkungan yang kompleks**.**

Di sisi lain, penggunaan *Machine Learning* dalam analisis spasial semakin berkembang. Putu Raditia Satriawan et al. (2024) melakukan kajian sistematik terhadap algoritma seperti *Decision Tree, Random Forest, SVM, kNN, CART, dan Artificial Neural Network* berbasis data penginderaan jauh. Studi tersebut menunjukkan bahwa *Random Forest* secara konsisten memberikan akurasi tertinggi, sementara *Decision Tree* unggul dalam interpretabilitas. Temuan ini menunjukkan relevansi kedua algoritma tersebut untuk pemodelan spasial yang melibatkan variabel biofisik. Meskipun demikian, sebagian besar kajian tersebut berfokus pada klasifikasi tutupan lahan atau objek spasial, dan belum secara spesifik diarahkan pada prediksi kelas kesesuaian lahan berbasis kriteria agroekologi.

Meskipun penelitian terdahulu telah membahas pemetaan kelapa sawit berbasis citra satelit, evaluasi kesesuaian lahan menggunakan pendekatan SIG, serta analisis performa berbagai algoritma *Machine Learning*, masih terdapat keterbatasan dalam integrasi ketiga pendekatan tersebut secara komprehensif. Sebagian besar studi kesesuaian lahan masih mengandalkan metode matching deterministik, sementara penerapan algoritma *Machine Learning* lebih banyak difokuskan pada klasifikasi tutupan lahan. Selain itu, perbandingan kinerja *Decision Tree* dan *Random Forest* dalam memprediksi kelas kesesuaian lahan kelapa sawit berbasis variabel biofisik yang juga berkaitan dengan kerawanan banjir dan tanah longsor masih jarang dilakukan, khususnya pada skala wilayah regional yang kompleks seperti Pulau Sumatra. Oleh karena itu, penelitian ini diarahkan untuk mengisi celah tersebut melalui pengembangan dan evaluasi model prediktif berbasis data spasial yang mampu memberikan informasi kesesuaian lahan secara lebih adaptif dan kontekstual terhadap risiko bencana hidrometeorologis.

Tabel 2 Perbandingan Penelitian Terdahulu dan Penelitian Ini

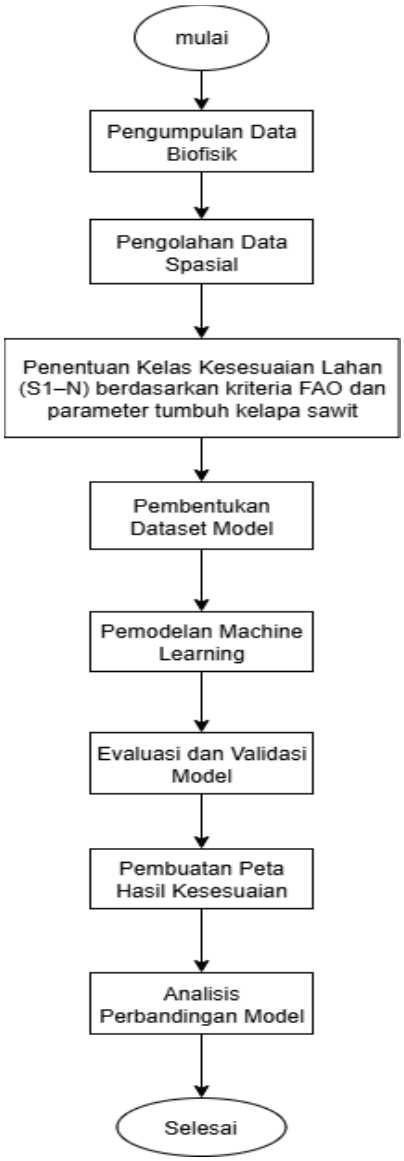
Aspek	**Penelitian Terdahulu**	**Penelitian Ini**
Objek Kajian	Evaluasi lahan atau pemetaan tutupan lahan pada wilayah terbatas	Kesesuaian lahan kelapa sawit skala regional Pulau Sumatra
Pendekatan	GIS deterministik atau *Machine Learning* tunggal	Integrasi GIS dan *Machine Learning*
Algoritma	Umumnya *Random Forest* atau metode *matching*	Perbandingan *Decision Tree* dan *Random Forest*
Variabel	Fokus pada faktor biofisik tertentu	Variabel biofisik lengkap (lereng, iklim, tanah, tutupan lahan)
Skala Wilayah	Lokal / sub-regional	Regional (Pulau Sumatra)
Keluaran	Peta kesesuaian atau klasifikasi lahan	Peta kesesuaian + evaluasi performa model
Kelemahan Umum	Tidak membandingkan model atau skala terbatas	Menjawab celah komparasi dan skala regional

Tabel 2 menyajikan perbandingan antara karakteristik penelitian terdahulu dan penelitian ini. Berdasarkan perbandingan tersebut, terlihat bahwa sebagian besar penelitian sebelumnya masih berfokus pada pendekatan deterministik atau penerapan algoritma tunggal dengan cakupan wilayah terbatas. Penelitian ini diarahkan untuk mengisi celah tersebut dengan melakukan perbandingan algoritma *Decision Tree* dan *Random Forest* berbasis data spasial biofisik pada skala regional Pulau Sumatra.

BAB III

METODE PENELITIAN

3.1 Tahapan penelitian



Gambar 1 Tahapan Penelitian

3.2 Pengumpulan Data

3.2.1 Waktu dan Tempat Penelitian

Penelitian ini dilaksanakan pada periode Januari hingga Maret 2026. Wilayah studi mencakup seluruh Pulau Sumatra, termasuk provinsi Aceh, Sumatera Utara, Riau, Kepulauan Riau, Sumatera Barat, Jambi, Sumatera Selatan, Bengkulu, Lampung, dan Bangka Belitung. Pemilihan wilayah Sumatra didasarkan pada karakteristik biofisiknya yang kompleks serta tingginya tingkat kejadian banjir dan tanah longsor dalam beberapa tahun terakhir, sehingga relevan sebagai lokasi kajian kesesuaian lahan dan analisis risiko lingkungan.

Penelitian ini dilakukan sepenuhnya melalui pendekatan non-lapangan dengan memanfaatkan data sekunder dan data spasial bersumber dari lembaga resmi. Seluruh proses pengolahan data, visualisasi, dan pemodelan prediktif dilakukan secara digital di Laboratorium Komputasi dan Sistem Informasi menggunakan perangkat lunak QGIS 3.28, ArcGIS 10.8, dan bahasa pemrograman Python. Pemilihan metode ini memungkinkan analisis pada skala regional yang luas, serta mendukung integrasi berbagai variabel biofisik yang diperlukan dalam pemodelan kesesuaian lahan kelapa sawit berbasis *Machine Learning.*

3.2.2 Jenis dan Sumber Data

Penelitian ini menggunakan data sekunder yang terdiri dari data spasial dan data non-spasial. Seluruh data diperoleh dari portal resmi dan lembaga penyedia data geospasial yang kredibel. Data ini digunakan untuk menggambarkan kondisi biofisik Pulau Sumatra yang berpengaruh terhadap kesesuaian lahan dan potensi kerentanan banjir serta tanah longsor.

1. Data Spasial

   Data spasial digunakan sebagai variabel utama dalam analisis kesesuaian lahan dan pemodelan *Machine Learning*. Variabel biofisik yang dipilih merupakan faktor yang memengaruhi pertumbuhan kelapa sawit sekaligus berhubungan dengan kondisi kerawanan banjir dan longsor di Sumatra.

Tabel 3 Data Spasial

No	Jenis Data	Format	Resolusi	Fungsi / Deskripsi	Sumber Data
1	Digital Elevation Model (DEM SRTM)	Raster (*.tif*)	30 m	Menentukan ketinggian dan kemiringan lereng	USGS – *Earth Explorer*
2	Curah Hujan Rata-rata Tahunan	Raster (*.tif*)	1 km	Menentukan tingkat ketersediaan air	CHIRPS v2.0
3	Suhu Rata-rata Tahunan	Raster (*.tif*)	1 km	Menilai kesesuaian iklim untuk pertumbuhan sawit	ERA5-Land – ECMWF
4	Tekstur Tanah	Raster (*.tif*)	250 m	Menentukan klasifikasi tanah berdasarkan proporsi pasir, debu, liat	SoilGrids
5	pH Tanah	Raster (*.tif*)	250 m	Parameter kesesuaian kimia tanah	SoilGrids
6	Sifat Tanah Lapisan Atas (0–30 cm) /Kedalaman Efektif Tanah	Raster (*.tif*)	250 m	Menentukan kapasitas perakaran sawit	SoilGrids
7	Tutupan Lahan (Land Use Land Cover)	Vektor (*.shp*)	30 m	Mengidentifikasi jenis penggunaan lahan eksisting	MODIS

2. Data Non Spasial

   Data non-spasial digunakan untuk mendukung analisis spasial menentukan parameter klasifikasi kesesuaian lahan, dan menyediakan acuan dalam proses *matching*. Jenis data non-spasial yang digunakan meliputi:

a. Dokumen klasifikasi kesesuaian lahan, seperti FAO Land Evaluation Framework dan Petunjuk Teknis Klasifikasi Tanah Nasional, yang digunakan sebagai dasar penentuan kelas S1, S2, S3, dan N.
b. Batas administrasi provinsi/kabupaten untuk proses pemetaan regional Pulau Sumatra (sumber: BIG).
c. Metadata dan dokumentasi teknis dataset (SoilGrids, ERA5-Land, USGS) untuk memastikan standar kualitas dan validitas data.
d. Label kelas kesesuaian lahan (S1–N) yang diperoleh melalui proses matching berdasarkan parameter biofisik, bukan dari dataset siap pakai.

3.2.3 Penentuan Kelas Kesesuaian Lahan (S1, S2, S3, N)

Penentuan kelas kesesuaian lahan dalam penelitian ini mengacu pada Balai Besar Sumber Daya Lahan Pertanian. (2016) serta prinsip evaluasi lahan FAO yg ditunjukan pada Tabel 3. Kedua dokumen tersebut menyediakan batasan baku untuk komoditas kelapa sawit (*Elaeis guineensis*), sehingga dapat digunakan sebagai dasar dalam menentukan tingkat kesesuaian lahan. Kelas kesesuaian dibagi menjadi empat kategori, yaitu S1 (sangat sesuai), S2 (cukup sesuai), S3 (sesuai marginal), dan N (tidak sesuai). Proses penilaian dilakukan pada setiap piksel data spasial dengan mencocokkan nilai parameter biofisik seperti suhu, curah hujan, bulan kering, drainase, tekstur tanah, kedalaman tanah, pH, dan kemiringan lereng terhadap kriteria yang tercantum dalam BBSDLP. Parameter-parameter tersebut berperan penting dalam menentukan karakteristik biofisik wilayah dan kesesuaian lahan kelapa sawit pada skala regional Pulau Sumatra.

Klasifikasi kesesuaian dilakukan menggunakan pendekatan *limiting factor*, yaitu metode yang menentukan kelas akhir berdasarkan parameter yang memiliki tingkat pembatas terendah. Pendekatan ini sejalan dengan konsep evaluasi lahan FAO, di mana kualitas lahan dianggap setara dengan faktor yang paling membatasi dalam mendukung pertumbuhan tanaman. Dengan demikian, jika salah satu parameter berada

pada kategori S3 atau N, maka keseluruhan piksel diklasifikasikan pada kelas tersebut meskipun parameter lain menunjukkan kondisi yang lebih baik.

Tabel 4 Kriteria Kesesuaian Lahan Kelapa Sawit (Elaeis guineensis Jacq.)

Parameter	**S1 – Sangat Sesuai**	**S2 – Cukup Sesuai**	**S3 – Marginal**	**N – Tidak Sesuai**
Suhu (°C)	24 – 28	>28–31 atau 22–24	>31–33 atau 20–22	>33 atau <20
Curah Hujan (mm/thn)	1.700–3.000	1.450–<1.700 atau >3.000	1.250–<1.450	<1.250
Bulan Kering (<100 mm)	<1	1–<2	2–3	>3
Tekstur	halus, agak halus	sedang	agak kasar	kasar
Bahan kasar (%)	<15	15–35	35–55	>55
Kedalaman tanah (cm)	>100	75–100	50–75	<50
pH H_2O	5.0–6.5	4.2–5.0 atau 6.5–7.0	<4.2 atau >7.0	Sangat masam / ekstrim
KTK tanah (cmol/kg)	>16	5–16	<5	-
Kejenuhan Basa (%)	>20	≤20	-	-
Lereng (%)	<8	8–15	15–30	>30

Langkah Penentuan Label Kesesuaian:

1. Mengambil nilai parameter (pH, suhu, curah hujan, tekstur, kedalaman tanah, kemiringan lereng) dari setiap piksel.
2. Menyamakan satuan dan format data sesuai kebutuhan klasifikasi.
3. Mengubah nilai numerik menjadi kelas S1–S3–N berdasarkan tabel BBSDLP.
4. Menerapkan prinsip *limiting factor* untuk menentukan kelas akhir.

5. Menghasilkan layer atau kolom “kelas_kesesuaian” yang digunakan sebagai label (target) pada model *Decision Tree* dan *Random Forest*.

Dalam penelitian ini, kelas kesesuaian lahan yang ditentukan berdasarkan pendekatan deterministik FAO dan Petunjuk Teknis BBSDLP digunakan sebagai acuan awal (*baseline*) untuk membangun dataset pelatihan model. Penggunaan algoritma *Machine Learning* tidak bertujuan untuk memverifikasi ulang kebenaran aturan FAO, melainkan untuk mengevaluasi kemampuan model sebagai pendekatan aproksimatif (*surrogate*) dalam mempelajari hubungan nonlinier antar variable biofisik serta konsistensi pola spasial kesesuaian lahan pada skala regional. Oleh karena itu, evaluasi model difokuskan pada perbandingan performa relatif antar algoritma, bukan pada validasi absolut terhadap kelas kesesuaian yang ditetapkan secara deterministik. Dengan pendekatan ini, *Machine Learning* berfungsi sebagai alat analisis komparatif untuk menilai efektivitas algoritma *Decision Tree* dan *Random Forest* dalam memodelkan kesesuaian lahan kelapa sawit.

3.2.4 Metode Pengumpulan Data

Metode pengumpulan data pada penelitian ini dilakukan untuk memperoleh seluruh variabel biofisik yang dibutuhkan dalam proses evaluasi kesesuaian lahan dan pemodelan *Machine Learning.* Pengumpulan data dilakukan secara terstruktur melalui tahapan identifikasi sumber data, pengunduhan, verifikasi, serta penyesuaian format data agar selaras dengan kebutuhan analisis spasial dan klasifikasi S1–N sebagaimana dijelaskan pada Subbab 3.2.3.Adapun tahapan pengumpulan data adalah sebagai berikut:

1. Identifikasi Variabel dan Sumber Data

   Variabel-variabel yang diperlukan ditentukan terlebih dahulu berdasarkan kebutuhan analisis kesesuaian lahan kelapa sawit, yaitu pH tanah, tekstur tanah, kedalaman efektif tanah, curah hujan tahunan, suhu udara rata-rata tahunan, dan

kemiringan lereng (diturunkan dari DEM). Daftar lengkap serta detail sumber data telah dijelaskan pada Tabel Jenis dan Sumber Data (Subbab 3.2.2).

2. Pengunduhan Data Spasial

   Seluruh data spasial (raster dan vektor) diunduh melalui sumber resmi seperti:

   a. *USGS Earth Explorer (DEM SRTM)*
   b. *WorldClim* versi 2 (curah hujan dan suhu)
   c. *SoilGrids* (pH tanah, tekstur, kedalaman tanah)
   d. *Geoportal BIG dan MODIS* (batas administrasi dan tutupan lahan)

   Setiap data diunduh menggunakan format standar GIS seperti .tif (*raster*) dan .shp (*vektor*).

3. Verifikasi Kualitas Data

   Semua data diverifikasi melalui:

   a. Pengecekan konsistensi koordinat
   b. Kelengkapan layer
   c. Resolusi spasial
   d. Kesesuaian format
   e. Pengecekan nilai ekstrem atau data kosong (no-data)

   Langkah ini penting agar data dapat diproses secara akurat pada tahap klasifikasi S1–N dan pelatihan model.

4. Penyesuaian Sistem Koordinat

   Seluruh dataset diseragamkan ke sistem proyeksi WGS 84 (EPSG:4326), sesuai standar pemetaan untuk wilayah Pulau Sumatera. Penyeragaman koordinat memastikan setiap layer bisa ditumpangtindihkan dengan benar pada proses ekstraksi nilai piksel.

5. Pemotongan Wilayah (*Clipping*)

   Layer spasial dipotong menggunakan batas administrasi Pulau Sumatera sehingga seluruh variabel berada pada area studi yang sama. Pemotongan wilayah dilakukan sebelum proses klasifikasi S1–N dan sebelum penggabungan dataset.

6. Penyusunan Dataset Kesesuaian Lahan

   Setelah semua data siap digunakan, nilai variabel biofisik diekstraksi untuk setiap piksel dan dikonsolidasikan ke dalam format tabular (CSV). Nilai-nilai ini kemudian digunakan sebagai masukan pada proses klasifikasi kesesuaian lahan (S1, S2, S3, N) berdasarkan Tabel Kriteria BBSDLP (Subbab 3.2.3).

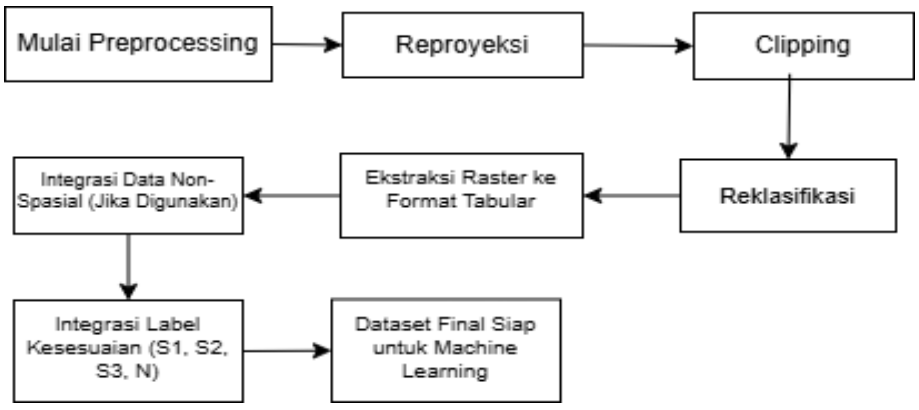
   Dataset akhir yang terbentuk memuat:

   a. Variabel input (ph, curah hujan, suhu, tekstur, kedalaman tanah, lereng)
   b. Label kesesuaian (kelas_kesesuaian: S1–N)

   Dataset ini kemudian digunakan pada tahap pemodelan *Decision Tree* dan *Random Forest*.

3.2.5 Pengolahan Awal Data (*Pre-processing*)

Tahap pengolahan awal data dilakukan untuk memastikan kualitas, keterlaksanaan, dan kesiapan data spasial sebelum digunakan dalam pemodelan *Machine Learning*. Mengingat cakupan wilayah penelitian meliputi seluruh Pulau Sumatra dengan resolusi dan jumlah piksel yang sangat besar, tahapan ini tidak hanya bertujuan untuk standarisasi data, tetapi juga untuk menjamin efisiensi komputasi dan mencegah bias spasial. Oleh karena itu, proses *pre-processing* mencakup sampling spasial terstratifikasi**,** pembersihan data, serta transformasi data raster ke dalam format dataset pembelajaran mesin.Tahapan pre-processing dilakukan pada gambar 2.



Gambar 2 Tahap Preprocessing

1. Reproyeksi dan Pemotongan Wilayah (Clipping)

Seluruh layer spasial diseragamkan ke sistem koordinat WGS 84 / UTM Zone 47N agar berada dalam sistem referensi yang sama. Setelah itu, setiap layer dipotong (clipping) menggunakan batas administrasi Pulau Sumatera sehingga area analisis hanya mencakup wilayah penelitian.

2. Reklasifikasi Variabel Biofisik

Nilai parameter biofisik seperti pH tanah, curah hujan tahunan, suhu udara, tekstur tanah, kedalaman efektif tanah, dan kemiringan lereng diklasifikasikan menjadi kelas kesesuaian S1, S2, S3, dan N. Reklasifikasi dilakukan berdasarkan Balai Besar Sumber Daya Lahan Pertanian (2016) dan menggunakan pendekatan *limiting factor*, di mana kelas akhir ditentukan oleh variabel yang paling membatasi.

3. Ekstraksi Raster ke Format Tabular

Setiap layer hasil reklasifikasi diekstraksi sehingga nilai piksel untuk seluruh variabel dapat dikonversi menjadi data tabular (CSV). Proses ini menghasilkan dataset yang memuat seluruh parameter biofisik pada setiap piksel wilayah penelitian.

4. Integrasi Data Non-Spasial (Jika Digunakan)

Data non-spasial seperti produktivitas atau data pendukung lainnya hanya digunakan sebagai pembanding/validasi, bukan sebagai fitur pada model *Machine Learning*. Oleh karena itu, integrasi data non-spasial dilakukan secara terpisah dan tidak dicampurkan ke dataset pelatihan.

5. Integrasi Label Kesesuaian (S1, S2, S3, N)

Label kesesuaian lahan ditentukan berdasarkan kriteria (Balai Besar Sumber Daya Lahan Pertanian (2016) dan diberikan pada setiap piksel hasil ekstraksi. Label kesesuaian lahan dimasukkan ke dalam dataset tabular sebagai variabel target untuk pemodelan *Decision Tree* dan *Random Forest*, dengan tujuan mengevaluasi kemampuan model dalam mempelajari hubungan antar variabel biofisik dan melakukan generalisasi spasial.

Tahap pre-processing menghasilkan dataset akhir yang telah terstandardisasi dan siap digunakan pada tahap pemodelan *Machine Learning*.

3.2.6 Hasil Pengumpulan Data

Hasil dari tahapan pengumpulan dan pengolahan awal data menghasilkan tiga komponen utama, yaitu:

1. Layer spasial terstandarisasi yang mencakup data *Digital Elevation Model* (DEM)**,** peta tanah**,** tutupan lahan, serta data iklim (curah hujan dan suhu)**.** Semua data telah diseragamkan proyeksinya ke WGS 84 UTM Zone 47N dan dipotong sesuai batas wilayah penelitian di Pulau Sumatera.
2. Dataset terintegrasi berupa gabungan antara data spasial dan non-spasial dalam format tabel (CSV). Dataset ini berisi nilai-nilai variabel biofisik yang telah direklasifikasi dan dinormalisasi, siap digunakan sebagai input pada model *Decision Tree* dan *Random Forest* untuk prediksi kesesuaian lahan kelapa sawit.
3. Metadata dan dokumentasi sumber data yang mencakup informasi asal lembaga**,** tahun perolehan**,** resolusi spasial, dan format file. Metadata ini digunakan untuk menjamin transparansi, keterlacakan, dan validitas data yang digunakan dalam penelitian.
4. Dataset Final untuk Pemodelan *Machine Learning*, hasil akhir dari proses pengolahan data berupa sebuah dataset terintegrasi dalam format CSV, yang menggabungkan seluruh variabel biofisik hasil ekstraksi data spasial serta label kesesuaian lahan (S1, S2, S3, N). Dataset ini digunakan sebagai input utama dalam pelatihan model *Decision Tree* dan *Random Forest*.

   Struktur dataset final ditujukan pada tabel 4.

Tabel 5 Struktur Dataset

No	Variabel	Tipe Data	Sumber	Keterangan
1	DEM	Numerik	DEM SRTM	Elevasi/ketinggian permukaan lahan (meter dpl)
2	*Slope*	Numerik	DEM SRTM	Kemiringan (%)
3	*Rainfall*	Numerik	ERA5-Land	Curah hujan tahunan

No	Variabel	Tipe Data	Sumber	Keterangan
4	prec	Numerik	ERA5-Land	Presipitasi/curah hujan dari data iklim
5	Temperature (rata-rata tmin dan tmax)	Numerik	ERA5-Land	Suhu rata-rata tahunan
6	Soil_pH	Numerik	SoilGrids	Derajat keasaman tanah
7	clay	Numerik	SoilGrids	Persentase fraksi liat (clay content) dalam tanah (%)
8	bulk	Numerik	SoilGrids	Bulk Density (kepadatan isi tanah), g/cm^3 atau kg/dm^3
9	CEC	Numerik	SoilGrids	Cation Exchange Capacity (KTK), kapasitas tukar kation tanah (cmol(+)/kg)
10	SOC	Numerik	SoilGrids	Soil Organic Carbon, kandungan karbon organik tanah (g/kg)
11	Landcover	Kategorikal	MODIS / BIG	Jenis tutupan lahan
12	Label	Kategorikal	Dokumen Klasifikasi Tanah Nasional	S1, S2, S3, N

Dataset kemudian dibagi menjadi:

a. 80% data pelatihan (training)
b. 20% data pengujian (testing)

Pembagian ini digunakan untuk mengevaluasi performa kedua algoritma.

3.3 Metode Penelitian

Metode penelitian yang digunakan dalam penelitian ini adalah metode kuantitatif dengan pendekatan penelitian kepustakaan (*library research*). Tahap ini dilakukan dengan cara mengumpulkan dan mempelajari berbagai sumber literatur yang

relevan, seperti buku, jurnal ilmiah, laporan penelitian, dan dokumen resmi dari lembaga terkait (FAO, BMKG, BIG, USGS, dan SoilGrids). Tujuannya adalah untuk memperoleh dasar teori, konsep, serta parameter biofisik yang menjadi acuan dalam penentuan kesesuaian lahan tanaman kelapa sawit. Referensi juga digunakan untuk memahami penerapan metode analisis spasial dan algoritma *Machine Learning* dalam bidang pertanian presisi dan evaluasi lahan (Goenadi et al. 2021; Li et al. 2024; Sathiyamurthi et al. 2024). Dalam konteks ini, pendekatan *Machine Learning* digunakan sebagai metode kuantitatif untuk menganalisis pola hubungan antar variabel biofisik dan membandingkan performa model prediktif, bukan sebagai pengganti metode evaluasi lahan berbasis aturan.

3.4 Validasi Model

Validasi model dilakukan untuk memastikan bahwa algoritma *Decision Tree* dan *Random Forest* yang digunakan dalam penelitian memiliki performa yang akurat, stabil, dan dapat digeneralisasi pada data baru. Proses validasi ini penting agar hasil prediksi kesesuaian lahan tidak hanya baik pada data pelatihan, tetapi juga konsisten ketika diterapkan di kondisi nyata. Tahapan validasi meliputi pembagian dataset, evaluasi menggunakan cross-validation, penanganan ketidakseimbangan kelas, serta pengukuran performa menggunakan berbagai metrik evaluasi.

3.4.1 Pembagian Dataset (Train–Test Split)

Dataset akhir yang telah terintegrasi, yang terdiri atas variabel biofisik dan label kesesuaian lahan (S1, S2, S3, dan N), dibagi menjadi data pelatihan (training set) dan data pengujian (testing set) menggunakan metode stratified random sampling. Pendekatan ini dipilih untuk memastikan proporsi setiap kelas kesesuaian lahan tetap terjaga pada data pelatihan maupun data pengujian, sehingga distribusi kelas pada kedua dataset tetap representatif terhadap distribusi data keseluruhan.

Proses pembagian data dilakukan dengan komposisi 80% data pelatihan dan 20% data pengujian. Data pelatihan digunakan untuk membangun model klasifikasi menggunakan algoritma *Decision Tree* dan *Random Forest*, sedangkan data pengujian digunakan untuk mengevaluasi performa model terhadap data yang tidak terlibat selama proses pelatihan. Penggunaan stratified sampling bertujuan untuk mengurangi potensi bias akibat ketidakseimbangan distribusi kelas serta menghasilkan evaluasi model yang lebih stabil dan representatif.

Selain itu, untuk mengukur konsistensi dan kemampuan generalisasi model, dilakukan evaluasi tambahan menggunakan *K-Fold Cross Validation* pada data pelatihan. Hasil evaluasi kemudian dianalisis menggunakan metrik *accuracy*, *precision*, *recall*, dan *F1-score* untuk membandingkan performa kedua algoritma dalam klasifikasi kesesuaian lahan kelapa sawit di Pulau Sumatra.

3.4.2 Validasi Silang K-Fold (*K-Fold Cross-Validation*)

Validasi silang *K-Fold* digunakan untuk memperoleh estimasi performa model yang lebih stabil dan tidak bergantung pada satu kali pembagian data. Pada metode ini, dataset dibagi ke dalam beberapa lipatan *(fold)* dengan proporsi yang sama. Model kemudian dilatih pada sebagian *fold* dan divalidasi pada *fold* yang tersisa, dilakukan secara bergantian hingga seluruh *fold* menjadi data validasi satu kali.Setiap siklus pelatihan–validasi menghasilkan skor performa, dan nilai akhir diperoleh dari rata-rata seluruh skor. Pendekatan ini bermanfaat untuk mengurangi bias serta memberikan gambaran yang lebih representatif mengenai kemampuan generalisasi model pada data baru.Penggunaan *K-Fold Cross-Validation* dalam penelitian ini diterapkan untuk mengevaluasi stabilitas dan konsistensi performa algoritma *Decision Tree* dan *Random Forest* pada dataset kesesuaian lahan kelapa sawit.

3.4.3 Metrik Evaluasi Model

Evaluasi dilakukan baik pada hasil cross-validation maupun data pengujian akhir. Metrik yang digunakan meliputi:

1. Akurasi

   Mengukur proporsi prediksi benar terhadap seluruh data.

$$Accuracy = \frac{TP+TN}{TP+TN+FP+FN} \quad (7)$$

   Keterangan:

   TP (*True Positive*) : Jumlah data yang diprediksi benar sebagai suatu kelas kesesuaian lahan (misalnya S1) dan memang berasal dari kelas tersebut.

   TN (*True Negative*) : Jumlah data yang bukan berasal dari suatu kelas tertentu dan diprediksi dengan benar sebagai bukan kelas tersebut.

   FP (*False Positive*) : Jumlah data yang diprediksi sebagai suatu kelas, tetapi sebenarnya berasal dari kelas lain.

   FN (*False Negative*) : Jumlah data yang seharusnya termasuk dalam suatu kelas, tetapi diprediksi sebagai kelas lain.

2. *Precision* dan *Recall* per kelas

   Cocok mengetahui kualitas prediksi pada masing-masing kelas S1, S2, S3, dan N.

$$Precision = \frac{TP}{TP+FP} \quad (8)$$

   Keterangan:

   TP (*True Positive*) : Jumlah data yang diprediksi benar sebagai suatu kelas.

   FP (*False Positive*) : Jumlah data yang diprediksi sebagai suatu kelas, tetapi sebenarnya bukan berasal dari kelas tersebut.

$$Recall = \frac{TP}{TP+FN} \quad (9)$$

Keterangan:

TP (*True Positive*)	:	Jumlah data yang diprediksi benar sebagai suatu kelas.
FN (*False Negative*)	:	Jumlah data yang berasal dari suatu kelas, tetapi gagal diprediksi oleh model.

3. *F1-score (Macro dan Weighted)*

   Digunakan untuk dataset yang tidak berimbang agar evaluasi tidak bias pada kelas mayoritas.

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall} \quad (10)$$

Keterangan:

Precision	:	Tingkat ketepatan prediksi model pada suatu kelas.
Recall	:	Tingkat keberhasilan model dalam mengenali seluruh data pada suatu kelas.

4. *Confusion Matrix*

   Digunakan untuk melihat pola kesalahan prediksi antar kelas dan mengidentifikasi kelas mana yang sulit diprediksi.

$$CMij = jumlah\ data\ kelas\ aktual\ i\ yang\ diprediksi\ sebagai\ kelas\ j \quad (11)$$

Keterangan:

CMij	:	Elemen matriks yang menunjukkan jumlah data dari kelas aktual ke-i yang diprediksi sebagai kelas ke-j.
I	:	Kelas aktual (S1, S2, S3, N).
J	:	Kelas hasil prediksi model (S1, S2, S3, N).

Dengan kombinasi metrik tersebut, performa model dapat dinilai secara menyeluruh, bukan hanya dari satu indikator.

3.4.4 Pemilihan Model Terbaik

Setelah seluruh proses validasi dilakukan, model terbaik ditentukan berdasarkan:

1. Nilai akurasi,
2. *Macro F1-score*,
3. Performa rata-rata cross-validation,
4. Pola kesalahan pada confusion matrix,
5. Stabilitas prediksi antar fold.

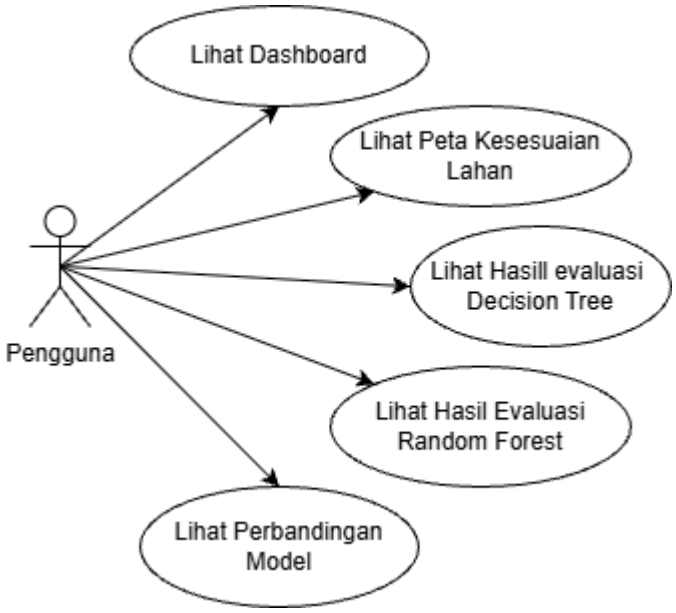
Model yang memiliki generalisasi terbaik dan kesalahan paling kecil pada kelas penting (misalnya S2 atau S3) akan dipilih sebagai model akhir untuk pembuatan peta kesesuaian lahan.

3.5 Rancangan penelitian

Subbab ini menjelaskan rancangan implementasi sistem yang digunakan untuk menyajikan hasil analisis kesesuaian lahan kelapa sawit berbasis model *Decision Tree* dan *Random Forest* dalam bentuk *Dashboard*. *Dashboard* dirancang sebagai media visualisasi untuk menampilkan peta hasil klasifikasi kesesuaian lahan, nilai metrik evaluasi model, serta perbandingan performa kedua algoritma secara ringkas dan informatif. Pemodelan sistem menggunakan *Unified Modeling Language* (UML) diterapkan sebagai alat bantu konseptual untuk menggambarkan alur proses utama, struktur komponen, dan interaksi pengguna dalam sistem, tanpa dimaksudkan sebagai perancangan sistem informasi secara menyeluruh. Oleh karena itu, pemodelan UML difokuskan pada representasi alur implementasi yang relevan dengan tujuan penelitian. pada subbab berikut.

3.5.1 Pemodelan UML

1. Use Case Diagram



Gambar 3 Usecase Diagram

Use Case Diagram menggambarkan interaksi antara pengguna dengan sistem visualisasi hasil prediksi kesesuaian lahan kelapa sawit yang dikembangkan. Pada diagram ini terdapat satu aktor, yaitu Pengguna, yang dapat mengakses seluruh fitur yang tersedia pada website. Adapun fungsi yang dapat dilakukan oleh pengguna adalah sebagai berikut:

A. Pengguna (User)

1. Lihat Dashboard

   Pengguna dapat mengakses halaman dashboard sebagai halaman utama sistem. Dashboard berfungsi untuk menampilkan informasi umum mengenai penelitian, ringkasan data, serta navigasi menuju fitur-fitur yang tersedia dalam website.

2. Lihat Peta Kesesuaian Lahan

   Pengguna dapat melihat peta kesesuaian lahan kelapa sawit hasil pemodelan yang ditampilkan dalam bentuk visualisasi spasial. Peta ini memberikan

informasi mengenai distribusi kelas kesesuaian lahan pada wilayah penelitian sehingga memudahkan interpretasi hasil analisis.

3. Lihat Hasil Evaluasi *Decision Tree*

   Pengguna dapat melihat hasil evaluasi model *Decision Tree* yang meliputi nilai *accuracy*, confusion matrix, classification report, serta metrik evaluasi lainnya. Informasi ini digunakan untuk mengetahui kemampuan model *Decision Tree* dalam melakukan klasifikasi kesesuaian lahan.

4. Lihat Hasil Evaluasi *Random Forest*

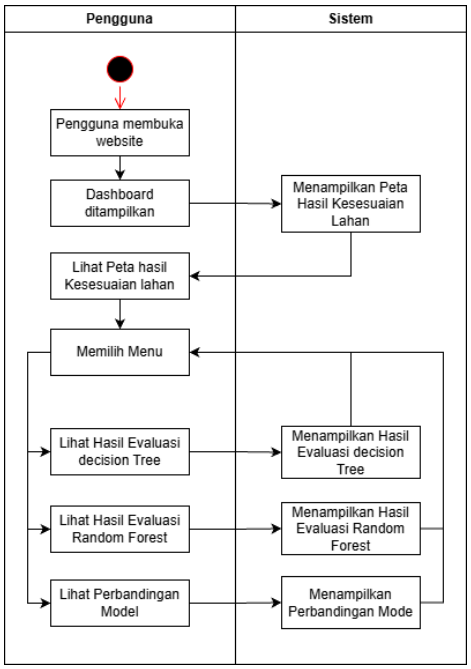
   Pengguna dapat melihat hasil evaluasi model *Random Forest* yang meliputi nilai *accuracy*, confusion matrix, classification report, serta metrik evaluasi lainnya. Hasil evaluasi ini digunakan untuk menilai performa model *Random Forest* dalam memprediksi kelas kesesuaian lahan.

5. Lihat Perbandingan Model

   Pengguna dapat membandingkan performa algoritma *Decision Tree* dan *Random Forest* berdasarkan hasil evaluasi yang diperoleh. Perbandingan ditampilkan dalam bentuk tabel maupun grafik sehingga memudahkan pengguna dalam mengidentifikasi model yang memberikan performa terbaik pada penelitian ini.

Berdasarkan use case diagram, sistem dirancang sebagai media visualisasi dan penyajian hasil analisis kesesuaian lahan kelapa sawit berbasis *Machine Learning*. Seluruh fitur dapat diakses secara langsung oleh pengguna melalui website sehingga pengguna dapat melihat hasil pemodelan, evaluasi, serta perbandingan performa algoritma secara interaktif dan informatif.

2. Activity Diagram



Gambar 4 Activity Diagram

Activity diagram menggambarkan alur interaksi antara pengguna dan sistem dalam mengakses website visualisasi hasil prediksi kesesuaian lahan kelapa sawit.

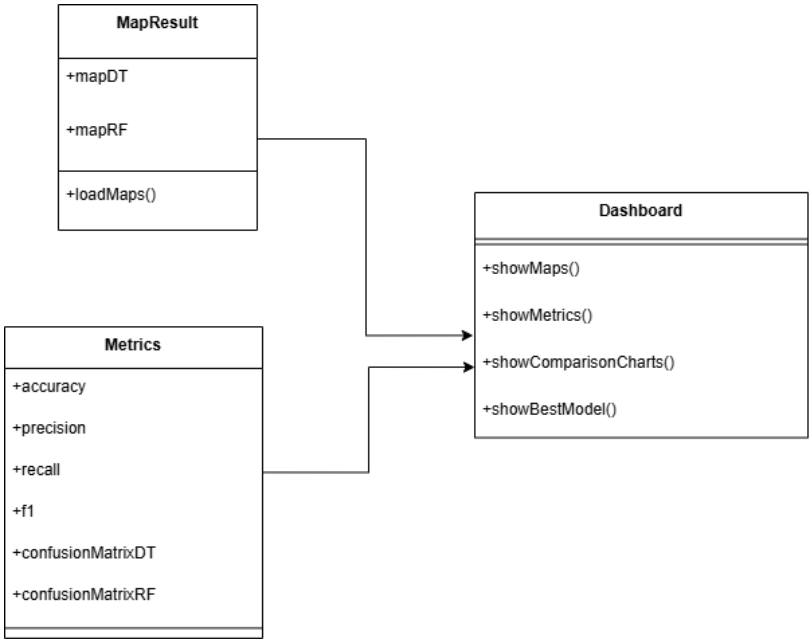
Alur proses pada activity diagram dapat dijelaskan sebagai berikut:

1. Pengguna membuka website dan sistem menampilkan halaman dashboard sebagai halaman utama.
2. Pengguna memilih menu "Lihat Peta Kesesuaian Lahan", kemudian sistem menampilkan peta hasil kesesuaian lahan berdasarkan data yang telah diproses.
3. Setelah melihat peta, pengguna dapat memilih menu lain yang tersedia pada sistem.
4. Jika pengguna memilih menu "Lihat Hasil Evaluasi *Decision Tree*", sistem menampilkan hasil evaluasi model *Decision Tree*.
5. Jika pengguna memilih menu "Lihat Hasil Evaluasi *Random Forest*", sistem menampilkan hasil evaluasi model *Random Forest*.

6. Jika pengguna memilih menu "Lihat Perbandingan Model", sistem menampilkan hasil perbandingan performa kedua model berdasarkan metrik evaluasi yang digunakan.
7. Setelah informasi ditampilkan, pengguna dapat kembali memilih menu lainnya sesuai kebutuhan.

Activity diagram ini menunjukkan bahwa sistem berfungsi sebagai media visualisasi hasil pemodelan dan evaluasi kesesuaian lahan kelapa sawit, di mana pengguna hanya memilih informasi yang ingin ditampilkan dan sistem akan memproses serta menyajikan hasil yang sesuai.

3. *Class* Diagram



Gambar 5 *Class* Diagram

Class diagram menggambarkan struktur sistem, data yang dikelola, serta hubungan antar kelas dalam website visualisasi hasil prediksi kesesuaian lahan kelapa sawit. Diagram ini terdiri dari tiga kelas utama, yaitu MapResult, Metrics, dan Dashboard.

A. Class MapResult

Kelas MapResult bertanggung jawab untuk menyimpan dan menyediakan data peta kesesuaian lahan yang akan ditampilkan pada website.

Atribut:

1. suitabilityMap

   Menyimpan data peta hasil klasifikasi kesesuaian lahan yang digunakan dalam sistem.

Metode:

1. loadMap()

   Digunakan untuk memuat data peta kesesuaian lahan ke dalam sistem sehingga dapat ditampilkan pada dashboard.

B. Class Metrics

Kelas Metrics digunakan untuk menyimpan hasil evaluasi performa model yang diperoleh dari proses pemodelan *Machine Learning*.

Atribut:

1. *accuracy*

   Menyimpan nilai akurasi model.

2. *precision*

   Menyimpan nilai *precision* model.

3. *recall*

   Menyimpan nilai *recall* model.

4. f1

   Menyimpan nilai *F1-score* model.

5. confusionMatrixDT

   Menyimpan confusion matrix hasil evaluasi model *Decision Tree*.

6. confusionMatrixRF

   Menyimpan confusion matrix hasil evaluasi model *Random Forest*.

Kelas ini berfungsi sebagai penyedia data evaluasi yang digunakan untuk analisis dan perbandingan performa model.

C. Class Dashboard

Kelas Dashboard merepresentasikan antarmuka utama yang digunakan untuk menampilkan informasi kepada pengguna.

Metode:

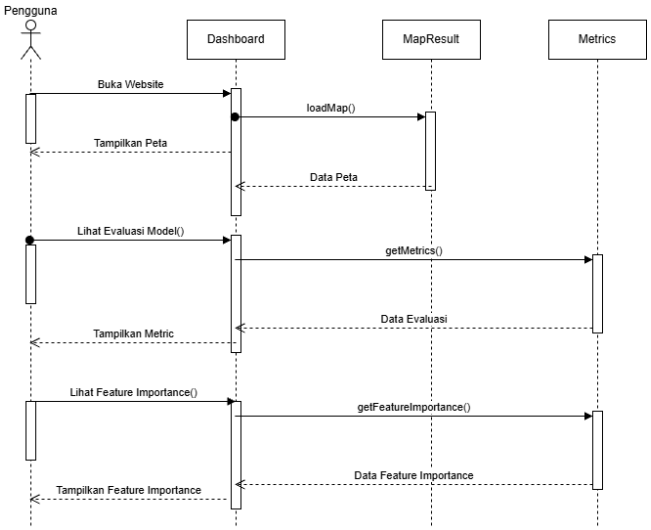
1. showMaps()
   Menampilkan peta kesesuaian lahan yang telah dimuat dari kelas MapResult.
2. showStatistics()
   Menampilkan statistik distribusi kelas kesesuaian lahan, seperti persentase kelas S1, S2, S3, dan N.
3. showMetrics()
   Menampilkan hasil evaluasi model yang diperoleh dari kelas Metrics.
4. showFeatureImportance()
   Menampilkan informasi feature importance untuk menunjukkan tingkat kontribusi masing-masing variabel biofisik terhadap hasil prediksi model.

Hubungan Antar Kelas

1. Dashboard menerima data peta dari kelas MapResult untuk ditampilkan kepada pengguna.
2. Dashboard menerima data evaluasi dari kelas Metrics untuk menampilkan metrik performa model dan informasi pendukung lainnya.

Dengan demikian, Dashboard berfungsi sebagai antarmuka utama yang menyajikan informasi kepada pengguna, sedangkan MapResult dan Metrics berperan sebagai penyedia data yang digunakan dalam proses visualisasi hasil penelitian.

4. Sequence Diagram



Gambar 6 Sequence Diagram

Sequence diagram menggambarkan urutan interaksi antara pengguna dengan sistem dalam mengakses informasi pada website visualisasi hasil prediksi kesesuaian lahan kelapa sawit. Diagram ini menunjukkan bagaimana Dashboard berinteraksi dengan kelas MapResult dan Metrics untuk menampilkan informasi kepada pengguna. Alur proses pada sequence diagram dapat dijelaskan sebagai berikut:

1. Pengguna membuka website.

   Sistem menampilkan halaman Dashboard sebagai halaman utama. Dashboard kemudian memanggil metode loadMap() pada kelas MapResult untuk memuat data peta kesesuaian lahan. Setelah data berhasil dimuat, MapResult mengirimkan data peta ke Dashboard dan sistem menampilkan peta kesesuaian lahan kepada pengguna.

2. Pengguna memilih menu Lihat Evaluasi Model.

   Dashboard memanggil metode getMetrics() pada kelas Metrics untuk mengambil data hasil evaluasi model. Kelas Metrics mengirimkan data evaluasi yang meliputi *accuracy*, *precision*, *recall*, *F1-score*, dan confusion matrix. Selanjutnya Dashboard menampilkan hasil evaluasi model kepada pengguna.

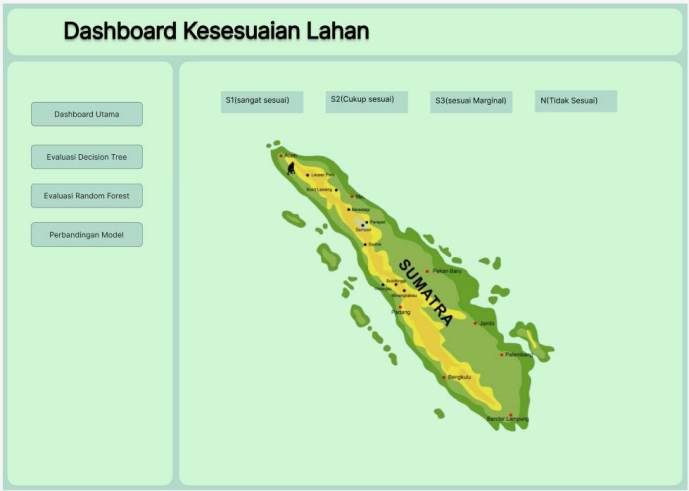
3. Pengguna memilih menu Lihat Feature Importance.

   Dashboard memanggil metode getFeatureImportance() pada kelas Metrics untuk mengambil data feature importance. Setelah data diterima, Dashboard menampilkan informasi tingkat kontribusi masing-masing variabel biofisik terhadap hasil prediksi model.

Sequence diagram ini menunjukkan bahwa Dashboard berfungsi sebagai penghubung antara pengguna dengan data hasil penelitian. Data peta diperoleh dari kelas MapResult, sedangkan data evaluasi model dan feature importance diperoleh dari kelas Metrics sebelum ditampilkan kepada pengguna.

3.5.2 Rancangan *User* Interface

1. Tampilan *Dashboard* Utama

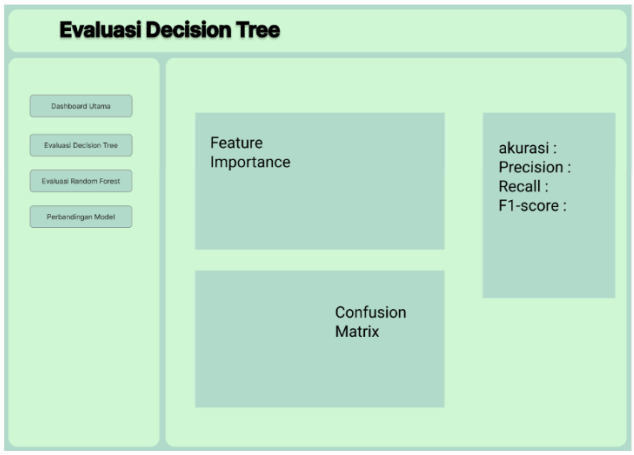


Gambar 7 Tampilan *Dashboard* Utama

Halaman Dashboard Utama merupakan halaman pertama yang ditampilkan ketika pengguna mengakses website. Halaman ini menyajikan gambaran umum mengenai hasil analisis kesesuaian lahan kelapa sawit di Pulau Sumatra. Pada bagian kiri terdapat menu navigasi yang digunakan untuk berpindah ke halaman Evaluasi *Decision Tree*, Evaluasi *Random Forest*, dan Perbandingan Model. Pada bagian utama ditampilkan peta kesesuaian lahan yang menunjukkan distribusi kelas kesesuaian

lahan, yaitu S1 (sangat sesuai), S2 (cukup sesuai), S3 (sesuai marginal), dan N (tidak sesuai). Tampilan ini dirancang untuk memberikan informasi awal mengenai kondisi kesesuaian lahan secara visual dan memudahkan pengguna dalam mengakses fitur analisis lainnya.

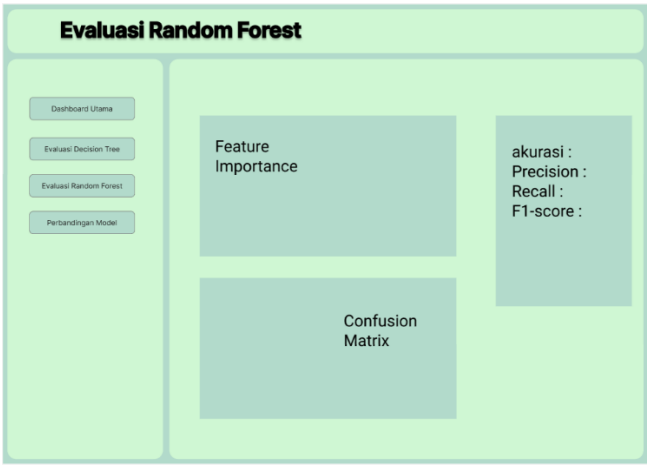
2. Tampilan Peta Hasil *Decision Tree*



Gambar 8 Tampilan Peta Hasil *Decision Tree*

Halaman Evaluasi *Decision Tree* digunakan untuk menampilkan hasil evaluasi model *Decision Tree* dalam memprediksi kesesuaian lahan kelapa sawit. Pada halaman ini ditampilkan nilai metrik evaluasi seperti *accuracy*, *precision*, *recall*, dan *F1-score* untuk mengukur performa model. Selain itu, tersedia visualisasi feature importance yang menunjukkan tingkat kontribusi masing-masing variabel biofisik terhadap hasil prediksi serta confusion matrix yang digunakan untuk menganalisis tingkat ketepatan klasifikasi pada setiap kelas kesesuaian lahan. Tampilan ini membantu pengguna memahami kinerja model *Decision Tree* secara lebih rinci.

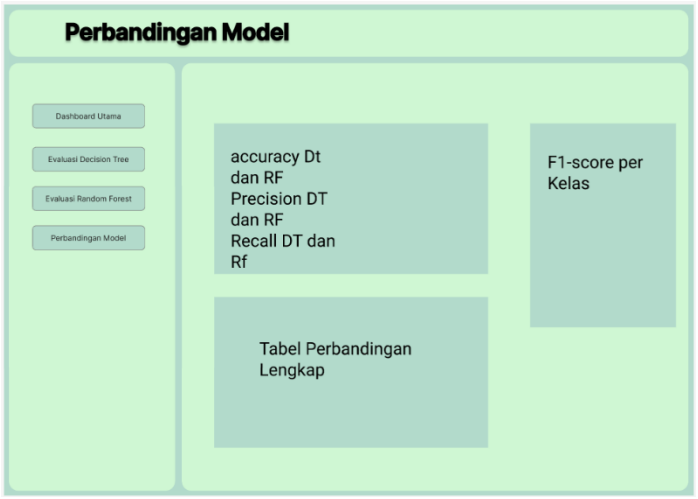
3. Tampilan Peta Hasil *Random Forest*



Gambar 9 Tampilan Peta Hasil *Random Forest*

Halaman Evaluasi *Random Forest* digunakan untuk menampilkan hasil evaluasi model *Random Forest* dalam memprediksi kesesuaian lahan kelapa sawit. Informasi yang ditampilkan meliputi metrik evaluasi berupa *accuracy*, *precision*, *recall*, dan *F1-score*, serta visualisasi feature importance yang menunjukkan pengaruh masing-masing variabel biofisik terhadap proses prediksi. Selain itu, ditampilkan confusion matrix untuk mengevaluasi hasil klasifikasi yang dihasilkan oleh model *Random Forest*. Halaman ini dirancang untuk memberikan informasi yang komprehensif mengenai performa model *Random Forest* sehingga dapat dibandingkan dengan model lainnya.

4. Tampilan Grafik Perbandingan Model



Gambar 10 Tampilan Grafik Perbandingan Model

Halaman Perbandingan Model digunakan untuk membandingkan performa algoritma *Decision Tree* dan *Random Forest* berdasarkan hasil evaluasi yang diperoleh. Pada halaman ini ditampilkan perbandingan nilai *accuracy*, *precision*, *recall*, dan *F1-score* dari kedua model. Selain itu, tersedia visualisasi *F1-score* untuk setiap kelas kesesuaian lahan serta tabel perbandingan yang menyajikan seluruh hasil evaluasi secara rinci. Tampilan ini membantu pengguna dalam mengidentifikasi model yang memiliki performa terbaik untuk memprediksi kesesuaian lahan kelapa sawit pada wilayah penelitian.

3.6 Jadwal penelitian

Jadwal penelitian disusun untuk memastikan setiap tahapan dapat terlaksana dengan terstruktur dan sesuai rencana. Penelitian ini diperkirakan berlangsung selama enam bulan, mulai dari tahap persiapan hingga penyusunan laporan akhir.

Tabel 6 Jadwal Penelitian

NO	JENIS KEGIATAN	2025			2026				
		10	11	12	1	2	3	4	5
1	Pengajuan Judul								
2	Penyusunan Proposal								
3	Seminar Proposal								
4	Studi literatur dan pengumpulan data sekunder								
5	Pengolahan awal data (pre-processing)								
6	Analisis spasial (QGIS/ArcGIS)								
7	Pemodelan *Machine Learning* (*Decision Tree* & *Random Forest*)								
8	Evaluasi hasil model dan interpretasi								
9	Penyusunan laporan dan revisi proposal								
9	Seminar Hasil								
10	Sidang Skripsi								

BAB IV
HASIL DAN PEMBAHASAN

4.1 Hasil Pengolahan Data

Berdasarkan hasil pengolahan data, seluruh variabel yang digunakan dalam penelitian ini telah berhasil diproses dan diintegrasikan menjadi dataset yang siap digunakan dalam pemodelan *Machine Learning*. Variabel penelitian terdiri dari data topografi, tanah, iklim, dan tutupan lahan yang diperoleh dari berbagai sumber data raster. Seluruh data melalui beberapa tahapan preprocessing untuk memastikan keseragaman data spasial sebelum dilakukan analisis. Tahapan preprocessing yang dilakukan meliputi:

1. *Clipping* sesuai batas wilayah penelitian (Pulau Sumatera)
2. *Reprojection* ke sistem koordinat yang seragam
3. *Resampling* raster ke resolusi spasial yang sama
4. *Raster alignment* untuk menyamakan grid piksel
5. Ekstraksi nilai raster menjadi data tabular
6. Integrasi data *slope* hasil analisis *terrain*

Selain itu, dilakukan pengecekan kualitas data untuk memastikan tidak terdapat data kosong (*missing value*) maupun kesalahan format data sebelum dilakukan proses klasifikasi dan pemodelan *Machine Learning*.

4.1.1 Contoh Dataset Hasil Ekstraksi

Tabel 7 Contoh Data Hasil Ekstraksi Raster untuk Pemodelan kesesuaian Lahan

Elevation	Clay Content	Soil pH	*Rainfall*	Tmax	Label
99	48.30	4.63	2973.45	31.16	S2

Elevation	Clay Content	Soil pH	*Rainfall*	Tmax	Label
38	44.07	4.69	2826.10	31.65	S1
586	42.49	5.00	3290.20	28.55	S3
52	42.67	4.80	3221.49	31.02	S2
3	43.71	4.77	2702.43	31.78	N

4.2 Ekstraksi dan Pembentukan Dataset

Setelah proses preprocessing selesai dilakukan, tahap berikutnya adalah ekstraksi nilai raster menjadi data tabular menggunakan titik sampel yang tersebar di wilayah penelitian. Setiap titik sampel merepresentasikan nilai seluruh variabel biofisik yang digunakan dalam penelitian. Variabel yang digunakan dalam penelitian ini meliputi:

1. Topografi: Elevasi (DEM) dan Kemiringan lereng (*Slope*)
2. Tanah: Bulk density, Cation Exchange Capacity (CEC), Clay, pH tanah, dan Soil Organic Carbon (SOC)
3. Iklim: Curah hujan (*Rainfall*), Presipitasi (Prec), Suhu maksimum (tmax), dan Suhu minimum (tmin)
4. Tutupan lahan: Landcover

Data *slope* diperoleh melalui analisis terrain menggunakan *Digital Elevation Model* (DEM), kemudian diintegrasikan kembali ke dalam dataset utama menggunakan koordinat spasial (X dan Y). Hasil ekstraksi kemudian disimpan dalam bentuk dataset tabular yang terdiri dari koordinat spasial dan seluruh variabel penelitian. Setelah

proses integrasi data selesai dilakukan, diperoleh sebanyak 2.732 data yang siap digunakan pada tahap klasifikasi dan pemodelan.

4.3 Pembersihan Data (Data Cleaning)

Dataset yang diperoleh selanjutnya melalui proses data cleaning untuk memastikan kualitas data sebelum dilakukan pemodelan *Machine Learning*. Tahapan yang dilakukan meliputi:

1. Penghapusan data yang memiliki nilai kosong (*missing values*)
2. Pengecekan kesesuaian tipe data
3. Penyesuaian struktur dataset hasil integrasi
4. Pengecekan nilai variabel hasil ekstraksi raster

Berdasarkan hasil pengecekan, seluruh data memiliki nilai valid sehingga tidak terdapat *missing value* pada dataset akhir. Setelah proses *cleaning* selesai dilakukan, jumlah data yang digunakan dalam penelitian ini sebanyak 2.732 data.

4.4 Penentuan Kelas Kesesuaian Lahan

Penentuan kelas kesesuaian lahan dilakukan menggunakan pendekatan *rule-based classification* berdasarkan metode *limiting factor*. Metode ini menentukan kelas kesesuaian akhir berdasarkan faktor pembatas terburuk dari setiap parameter yang digunakan. Variabel yang digunakan dalam proses klasifikasi meliputi:

1. Temperatur
2. Curah hujan
3. pH tanah
4. Kemiringan lereng (*slope*)
5. Clay sebagai pendekatan tekstur tanah

Nilai temperatur diperoleh dari rata-rata suhu maksimum dan suhu minimum menggunakan persamaan:

$$Temperature = \frac{tmax + tmin}{2} \quad (12)$$

Setiap variabel kemudian diklasifikasikan ke dalam kelas kesesuaian lahan berdasarkan kriteria FAO dan BBSDLP yang terdiri dari:

1. S1 : Sangat sesuai
2. S2 : Cukup sesuai
3. S3 : Sesuai marginal
4. N : Tidak sesuai

Kelas akhir ditentukan menggunakan metode *limiting factor* dengan mengambil nilai kelas terburuk dari seluruh parameter yang digunakan.

4.4.1 Distribusi Kelas Kesesuaian Lahan

Berdasarkan hasil klasifikasi kesesuaian lahan, diperoleh distribusi kelas sebagai berikut:

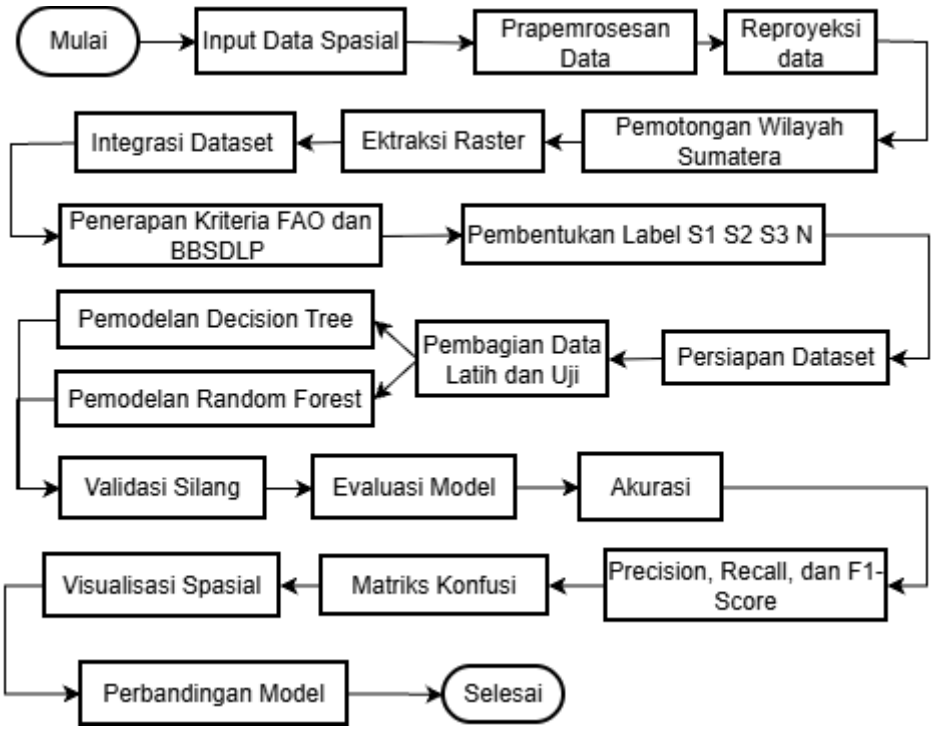
1. S2 : 1.664 data
2. S3 : 501 data
3. S1 : 397 data
4. N : 170 data

Hasil tersebut menunjukkan bahwa sebagian besar wilayah penelitian berada pada kelas S2 (cukup sesuai). Dominasi kelas S2 menunjukkan bahwa sebagian besar wilayah di Pulau Sumatera memiliki kondisi biofisik yang cukup mendukung untuk pengembangan kelapa sawit, namun masih memiliki beberapa faktor pembatas. Kelas S1 memiliki jumlah yang lebih sedikit karena hanya wilayah dengan kondisi biofisik optimal yang dapat masuk ke kategori sangat sesuai. Sementara itu, kelas S3 dan N umumnya berada pada wilayah dengan faktor pembatas yang cukup tinggi, seperti kemiringan lereng yang curam maupun kondisi tanah yang kurang mendukung. Distribusi kelas yang dihasilkan menunjukkan bahwa metode klasifikasi berbasis

limiting factor mampu menghasilkan pola kesesuaian lahan yang realistis sesuai kondisi biofisik wilayah penelitian.

4.5 Hasil Pemodelan *Machine Learning*

Pada tahap ini dilakukan proses pemodelan *Machine Learning* menggunakan algoritma *Decision Tree* dan *Random Forest* untuk memprediksi kelas kesesuaian lahan kelapa sawit. Dataset sebanyak 2.732 data dibagi menjadi data pelatihan dan data pengujian dengan rasio 80:20. Sebanyak 2.185 data digunakan sebagai data pelatihan dan 547 data digunakan sebagai data pengujian. Data pelatihan digunakan untuk membangun model, sedangkan data pengujian digunakan untuk mengevaluasi performa model terhadap data yang belum pernah dipelajari sebelumnya.



Gambar 11 Flowchart Implementasi Pemodelan *Machine Learning*

Proses pemodelan *Machine Learning* dilakukan melalui beberapa tahapan, mulai dari pembagian dataset, proses pelatihan model, evaluasi performa menggunakan confusion matrix dan classification report, hingga visualisasi hasil klasifikasi spasial.

4.5.1 *Decision Tree*

Model *Decision Tree* menghasilkan nilai *accuracy* sebesar 88,30%. Hasil confusion matrix menunjukkan bahwa sebagian besar data berhasil diklasifikasikan dengan benar. Namun masih ditemukan kesalahan klasifikasi terutama pada kelas S2 yang diprediksi sebagai kelas S1 sebanyak 39 data.

4.5.2 *Random Forest*

Model *Random Forest* menghasilkan *accuracy* sebesar 97,99% pada data uji. Hasil validasi silang menghasilkan rata-rata akurasi sebesar 98,57% dengan standar deviasi 0,45%, yang menunjukkan performa model yang tinggi dan stabil pada berbagai subset data. Hasil ini lebih tinggi dibandingkan *Decision Tree*. *Random Forest* mampu mengurangi kesalahan klasifikasi pada hampir seluruh kelas kesesuaian lahan, terutama pada kelas S2 yang sebelumnya sering salah diklasifikasikan oleh *Decision Tree*. Hal ini menunjukkan bahwa pendekatan ensemble learning mampu meningkatkan kemampuan model dalam mengenali pola data secara lebih stabil. *Random Forest* menunjukkan peningkatan performa yang signifikan dibandingkan *Decision Tree* dengan selisih *accuracy* sebesar 9,69%. Peningkatan ini menunjukkan bahwa pendekatan ensemble learning mampu mengurangi kesalahan klasifikasi dan meningkatkan kemampuan model dalam mengenali pola data kesesuaian lahan.

4.6 Evaluasi Model

Evaluasi model dilakukan menggunakan *accuracy*, confusion matrix, classification report, dan *K-Fold Cross Validation*. Perlu diperhatikan bahwa kelas kesesuaian lahan dalam penelitian ini dibentuk menggunakan pendekatan *rule-based classification* berdasarkan kriteria FAO dan BBSDLP. Oleh karena itu, performa

model *Machine Learning* yang tinggi menunjukkan kemampuan model dalam mempelajari pola klasifikasi yang dibentuk oleh aturan tersebut. Hasil penelitian ini tidak dimaksudkan untuk menggantikan evaluasi lapangan, melainkan sebagai pendekatan otomatisasi klasifikasi kesesuaian lahan berbasis data spasial.

4.6.1 *Accuracy*

Accuracy digunakan untuk mengukur tingkat ketepatan model dalam mengklasifikasikan data kesesuaian lahan. Nilai *accuracy* menunjukkan persentase jumlah data yang berhasil diprediksi dengan benar dibandingkan seluruh data pengujian. Berdasarkan hasil pengujian model, diperoleh nilai *accuracy* sebagai berikut:

Tabel 8 *Accuracy*

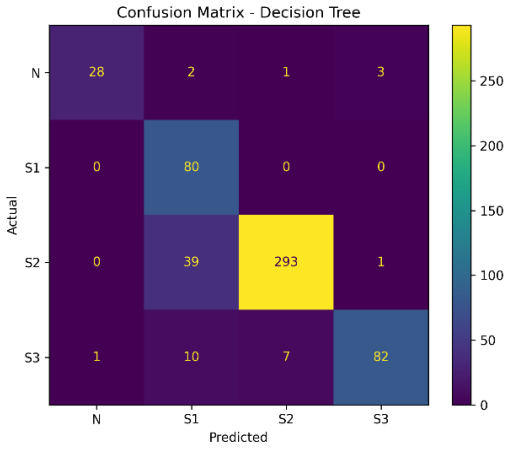
Model	***Accuracy***
Decision Tree	88.30%
Random Forest	97.99%

Berdasarkan hasil pengujian menggunakan data testing sebanyak 547 sampel, algoritma *Decision Tree* menghasilkan nilai *accuracy* sebesar 88,30%, sedangkan algoritma *Random Forest* menghasilkan *accuracy* sebesar 97,99%. Hasil ini menunjukkan bahwa kedua model mampu melakukan klasifikasi kesesuaian lahan dengan baik, namun *Random Forest* memberikan performa yang lebih tinggi dibandingkan *Decision Tree*.

Perbedaan akurasi tersebut menunjukkan bahwa pendekatan ensemble learning pada *Random Forest* mampu meningkatkan kemampuan model dalam mempelajari hubungan antar variabel biofisik dibandingkan pohon keputusan tunggal. Dengan demikian, *Random Forest* lebih efektif digunakan untuk memprediksi kelas kesesuaian lahan kelapa sawit pada wilayah yang memiliki karakteristik biofisik kompleks seperti Pulau Sumatra.

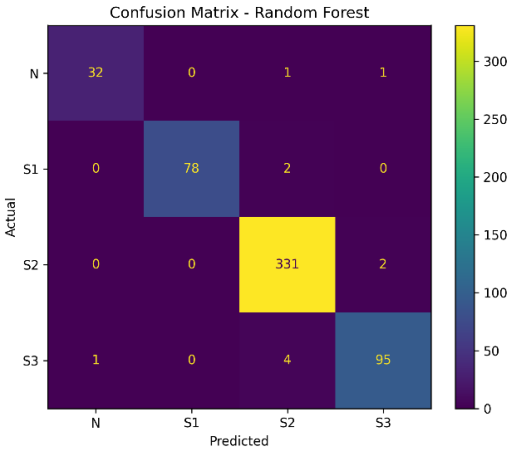
4.6.2 Confusion Matrix

Confusion matrix digunakan untuk melihat kemampuan model dalam mengklasifikasikan setiap kelas kesesuaian lahan secara detail. Berdasarkan hasil confusion matrix, sebagian besar data berhasil diprediksi dengan benar oleh kedua model.



Gambar 12 Confusion Matrix *Decision Tree*

Kesalahan klasifikasi terbesar pada model *Decision Tree* terjadi pada kelas S2 dan S3 yang diprediksi sebagai kelas S1. Fenomena ini menunjukkan bahwa karakteristik biofisik antara ketiga kelas tersebut memiliki kemiripan tertentu sehingga sulit dipisahkan secara sempurna oleh model pohon keputusan tunggal.



Gambar 13 Confusion Matrix *Random Forest*

Berbeda dengan *Decision Tree*, model *Random Forest* mampu mengurangi kesalahan klasifikasi secara signifikan. Sebagian besar sampel berhasil diprediksi dengan benar dan hanya terdapat sedikit kesalahan pada batas antara kelas S2 dan S3. Hasil ini menunjukkan bahwa pendekatan *ensemble learning* mampu meningkatkan kemampuan generalisasi model terhadap data yang kompleks.

4.6.3 Classification Report

Hasil *classification report* menunjukkan bahwa kedua model memiliki nilai *precision*, *recall*, dan *f1-score* yang tinggi pada seluruh kelas kesesuaian lahan. Pada model *Decision Tree*, nilai *accuracy* mencapai 88.30%, sedangkan *Random Forest* mencapai 97.99%. Nilai *precision* dan *recall* yang tinggi menunjukkan bahwa model mampu mengidentifikasi setiap kelas kesesuaian lahan dengan baik. Kesalahan klasifikasi yang terjadi umumnya berada pada kelas S2 dan S3 karena kedua kelas tersebut memiliki karakteristik biofisik yang relatif berdekatan.

Tabel 9 *Classification report Decision Tree*

Kelas	*Precision*	*Recall*	*F1-score*	*Support*
S1	0.61	1.00	0.76	80
S2	0.97	0.88	0.92	333
S3	0.95	0.82	0.88	100
n	0.97	0.82	0.89	34

Hasil *classification report* menunjukkan bahwa model *Decision Tree* memiliki kemampuan klasifikasi yang cukup baik pada seluruh kelas kesesuaian lahan. Nilai *precision* tertinggi diperoleh pada kelas N dan S2 sebesar 0,97, sedangkan *recall* tertinggi diperoleh pada kelas S1 sebesar 1,00. Hal ini menunjukkan bahwa seluruh sampel kelas S1 berhasil dikenali oleh model.

Namun demikian, nilai *precision* kelas S1 hanya sebesar 0,61 yang menunjukkan bahwa masih terdapat sejumlah sampel dari kelas lain yang

diklasifikasikan sebagai S1. Kondisi ini mengindikasikan adanya kecenderungan model *Decision Tree* melakukan *over-classification* pada kelas S1 sehingga menurunkan nilai *F1-score* menjadi 0,76.

Tabel 10 *Classification report Random Forest*

Kelas	*Precision*	*Recall*	*F1-score*	*Support*
S1	1.00	0.97	0.99	80
S2	0.98	0.99	0.99	333
S3	0.97	0.95	0.96	100
n	0.97	0.94	0.96	34

Hasil *classification report* menunjukkan bahwa model *Random Forest* memberikan performa yang sangat baik pada seluruh kelas kesesuaian lahan. Nilai *precision*, *recall*, dan *F1-score* berada pada rentang 0,94–1,00 untuk seluruh kelas. Kelas S2 memperoleh nilai *F1-score* sebesar 0,99 dengan *precision* 0,98 dan *recall* 0,99. Hasil ini menunjukkan bahwa model mampu mengidentifikasi kelas kesesuaian lahan dominan dengan tingkat kesalahan yang sangat rendah. Secara keseluruhan, nilai weighted average *F1-score* sebesar 0,98 menunjukkan bahwa *Random Forest* memiliki kemampuan klasifikasi yang sangat stabil dan konsisten.

Berdasarkan hasil classification report, kedua model menunjukkan performa klasifikasi yang sangat baik pada seluruh kelas kesesuaian lahan. Model *Random Forest* menghasilkan nilai *precision*, *recall*, dan *f1-score* yang sedikit lebih tinggi dibandingkan *Decision Tree*, yang menunjukkan bahwa pendekatan ensemble learning mampu meningkatkan kemampuan model dalam mengenali pola data secara lebih stabil. Kelas S2 memiliki nilai *precision* dan *recall* tertinggi pada kedua model. Hal ini disebabkan karena jumlah data pada kelas S2 lebih dominan dibandingkan kelas lainnya sehingga model memiliki lebih banyak pola data untuk dipelajari. Sementara itu, kesalahan klasifikasi masih ditemukan pada kelas S3 karena karakteristik biofisik pada kelas tersebut relatif berdekatan dengan kelas S2. Nilai *recall* yang tinggi

menunjukkan bahwa model mampu mengidentifikasi sebagian besar data pada masing-masing kelas dengan baik, sedangkan nilai *precision* yang tinggi menunjukkan bahwa prediksi yang dihasilkan model memiliki tingkat ketepatan yang tinggi. Dengan demikian, hasil *classification report* menunjukkan bahwa kedua model memiliki kemampuan generalisasi yang baik dalam memprediksi kelas kesesuaian lahan kelapa sawit di Pulau Sumatra.

4.6.4 Metrik Evaluasi Keseluruhan

Tabel 11 Perbandingan Metrik Evaluasi

Metrik	*Decision Tree*	*Random Forest*
Accuracy	88.30%	97.99%
Precision	91.62%	97.99%
Recall	88.30%	97.99%
F1-score	89.00%	97.98%
Error Rate	11.70%	2.01%

Berdasarkan seluruh metrik evaluasi, *Random Forest* menunjukkan performa yang lebih baik dibandingkan *Decision Tree*. Nilai error rate *Random Forest* hanya sebesar 2,01%, jauh lebih rendah dibandingkan *Decision Tree* yang mencapai 11,70%. Hasil ini menunjukkan bahwa *Random Forest* memiliki kemampuan prediksi yang lebih akurat dan lebih andal dalam mengklasifikasikan kesesuaian lahan kelapa sawit.

4.6.5 Cross Validation

Untuk menguji kestabilan model, dilakukan *K-Fold Cross Validation* dengan jumlah fold sebanyak 5. Hasil cross validation menunjukkan bahwa:

Tabel 12 Hasil *K-Fold Cross Validation*

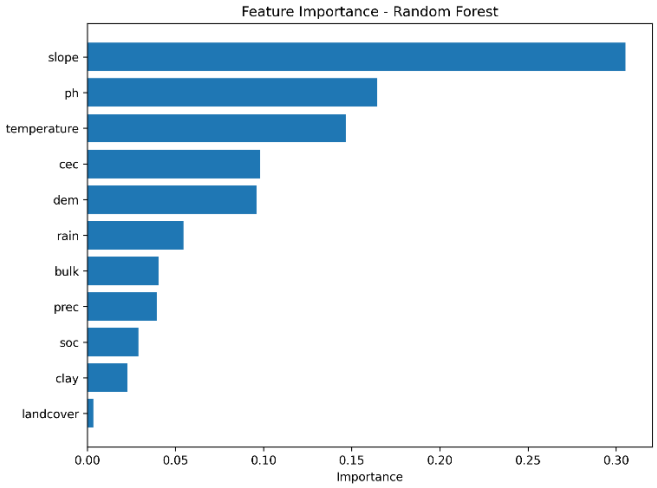
Model	Mean *Accuracy*	*Standar Deviation*
Decision Tree	89.06%	1.09%
Random Forest	98.57%	0.45%

Hasil *K-Fold Cross Validation* menunjukkan bahwa *Random Forest* memiliki rata-rata akurasi sebesar 98,57% dengan standar deviasi hanya 0,45%, sedangkan *Decision Tree* memperoleh rata-rata akurasi sebesar 89,06% dengan standar deviasi 1,09%. Nilai standar deviasi yang lebih kecil pada *Random Forest* menunjukkan bahwa model memiliki kestabilan yang lebih baik dan menghasilkan performa yang konsisten pada setiap fold pengujian. Selain menghasilkan *accuracy* yang lebih tinggi, *Random Forest* juga memiliki kemampuan generalisasi yang lebih baik dibandingkan *Decision Tree*. Hal ini mengindikasikan bahwa model memiliki kemampuan generalisasi yang baik dan tidak mengalami overfitting secara signifikan. Secara keseluruhan, *Random Forest* menunjukkan performa yang lebih baik dibandingkan *Decision Tree*, baik dari sisi *accuracy* maupun kestabilan model. Berdasarkan hasil cross validation, kedua model menunjukkan nilai rata-rata *accuracy* yang sangat tinggi dengan standar deviasi yang relatif kecil. Nilai standar deviasi yang kecil menunjukkan bahwa kedua model memiliki performa yang stabil dan konsisten pada berbagai pembagian data.

Selain itu, hasil ini menunjukkan bahwa model memiliki kemampuan generalisasi yang baik dan tidak mengalami overfitting secara signifikan. *Random Forest* menghasilkan nilai *accuracy* yang sedikit lebih tinggi dibandingkan *Decision Tree*, yang menunjukkan bahwa pendekatan ensemble learning mampu meningkatkan kestabilan model dalam proses klasifikasi kesesuaian lahan.

4.7 Analisis Feature Importance

Analisis feature importance dilakukan menggunakan algoritma *Random Forest* untuk mengetahui variabel yang paling berpengaruh dalam proses klasifikasi kesesuaian lahan. Berdasarkan hasil analisis, diperoleh urutan variabel paling berpengaruh sebagai berikut:



Gambar 14 Tampilan Feature Importance

Tabel 13 Ranking Feature Importance

Ranking	Variabel	Nilai Importance
1	*Slope*	0.305
2	Soil pH	0.164
3	Temperature	0.147
4	CEC	0.098
5	DEM	0.096

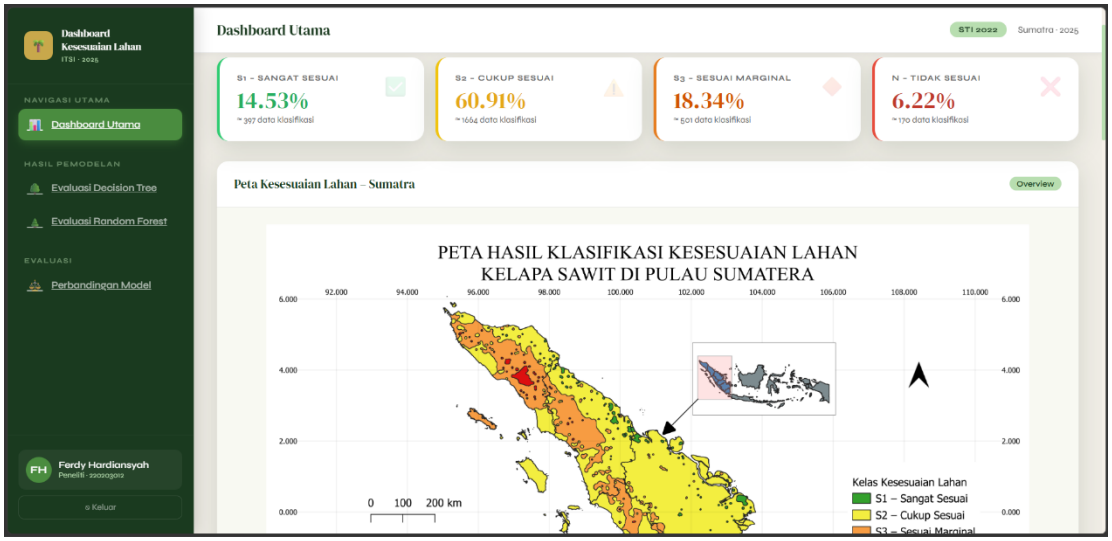
Hasil tersebut menunjukkan bahwa variabel *slope* memiliki kontribusi terbesar terhadap proses klasifikasi kesesuaian lahan kelapa sawit. Tingginya nilai importance pada variabel *slope* menunjukkan bahwa faktor topografi merupakan faktor pembatas utama dalam menentukan kesesuaian lahan di wilayah penelitian. Hal ini sesuai dengan karakteristik tanaman kelapa sawit yang memerlukan kondisi lereng relatif landai untuk mendukung pertumbuhan tanaman dan aktivitas pengelolaan lahan. Selain *slope*, variabel pH tanah dan temperatur juga menunjukkan nilai importance yang tinggi, yang mengindikasikan bahwa kondisi tanah dan iklim memiliki pengaruh penting terhadap tingkat kesesuaian lahan kelapa sawit. Variabel kapasitas tukar kation (CEC) dan elevasi (DEM) juga memberikan kontribusi yang cukup besar dalam proses klasifikasi, yang menunjukkan pentingnya karakteristik tanah dan kondisi topografi dalam

menentukan kesesuaian lahan. Sebaliknya, variabel landcover memiliki nilai *importance* paling rendah, yang menunjukkan bahwa variabel tersebut memiliki pengaruh yang relatif kecil dibandingkan variabel biofisik lainnya. Secara keseluruhan, hasil feature importance menunjukkan bahwa faktor topografi, kondisi tanah, dan iklim menjadi variabel dominan dalam proses klasifikasi kesesuaian lahan kelapa sawit di Pulau Sumatra.

4.8 Implementasi Sistem Visualisasi Berbasis Web

4.8.1 Dashboard Utama

Dashboard Utama merupakan halaman awal yang digunakan untuk menyajikan ringkasan hasil klasifikasi kesesuaian lahan kelapa sawit di Pulau Sumatra. Halaman ini dirancang untuk memberikan gambaran umum mengenai distribusi kelas kesesuaian lahan, hasil pemetaan spasial, serta informasi statistik yang dihasilkan dari proses klasifikasi menggunakan metode rule-based FAO dan BBSDLP.



Gambar 15 Dashboard Utama Kesesuaian Lahan

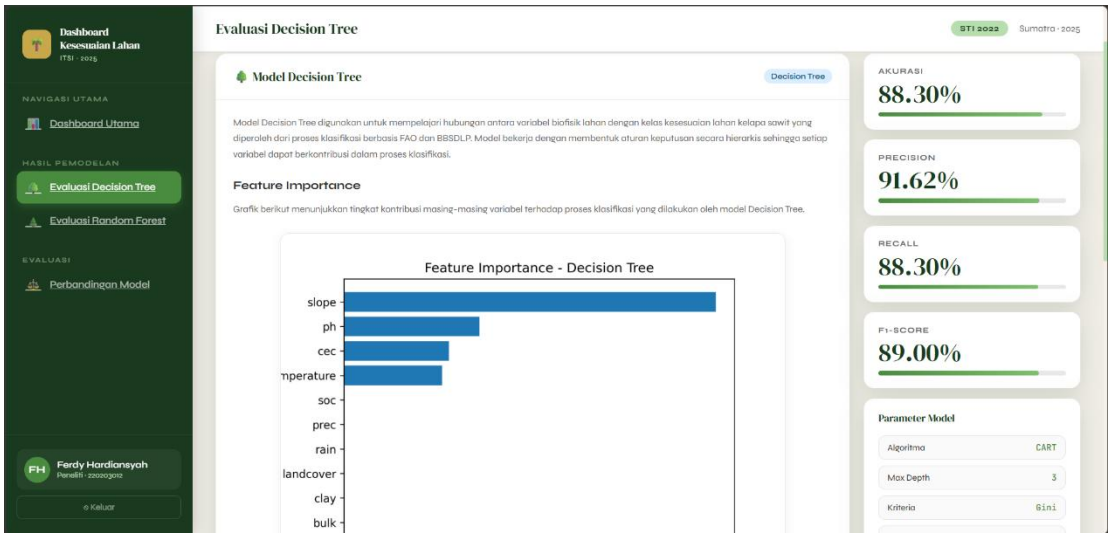
Pada bagian atas dashboard ditampilkan ringkasan jumlah dan persentase setiap kelas kesesuaian lahan, yaitu kelas S1 (Sangat Sesuai), S2 (Cukup Sesuai), S3 (Sesuai Marginal), dan N (Tidak Sesuai). Berdasarkan hasil klasifikasi yang diperoleh, kelas

S2 memiliki proporsi terbesar dengan jumlah 1.664 titik sampel (60,91%), diikuti oleh kelas S3 sebanyak 501 titik sampel (18,34%), kelas S1 sebanyak 397 titik sampel (14,53%), dan kelas N sebanyak 170 titik sampel (6,22%). Selanjutnya, dashboard menampilkan peta hasil klasifikasi kesesuaian lahan kelapa sawit di Pulau Sumatra. Peta tersebut memperlihatkan distribusi spasial kelas kesesuaian lahan berdasarkan hasil pengolahan data biofisik yang meliputi faktor topografi, iklim, dan sifat tanah. Setiap kelas ditampilkan menggunakan warna yang berbeda sehingga memudahkan pengguna dalam mengidentifikasi wilayah yang memiliki tingkat kesesuaian lahan tertentu.

Selain peta, dashboard juga menampilkan grafik distribusi kelas dan grafik proporsi kelas. Grafik distribusi digunakan untuk menunjukkan jumlah sampel pada setiap kelas kesesuaian lahan, sedangkan grafik proporsi digunakan untuk memperlihatkan persentase kontribusi masing-masing kelas terhadap keseluruhan data. Penyajian informasi dalam bentuk grafik bertujuan untuk mempermudah interpretasi hasil klasifikasi secara visual. Dashboard Utama juga berfungsi sebagai pusat navigasi menuju halaman evaluasi model *Decision Tree*, *Random Forest*, dan halaman perbandingan model yang digunakan dalam penelitian ini.

4.8.2 Halaman Evaluasi *Decision Tree*

Halaman Evaluasi *Decision Tree* digunakan untuk menampilkan hasil evaluasi model *Decision Tree* yang telah dibangun pada penelitian ini. Halaman ini menyediakan berbagai informasi yang berkaitan dengan performa model, sehingga pengguna dapat memahami kemampuan model dalam melakukan klasifikasi kesesuaian lahan kelapa sawit.



Gambar 16 Halaman Evaluasi *Decision Tree*

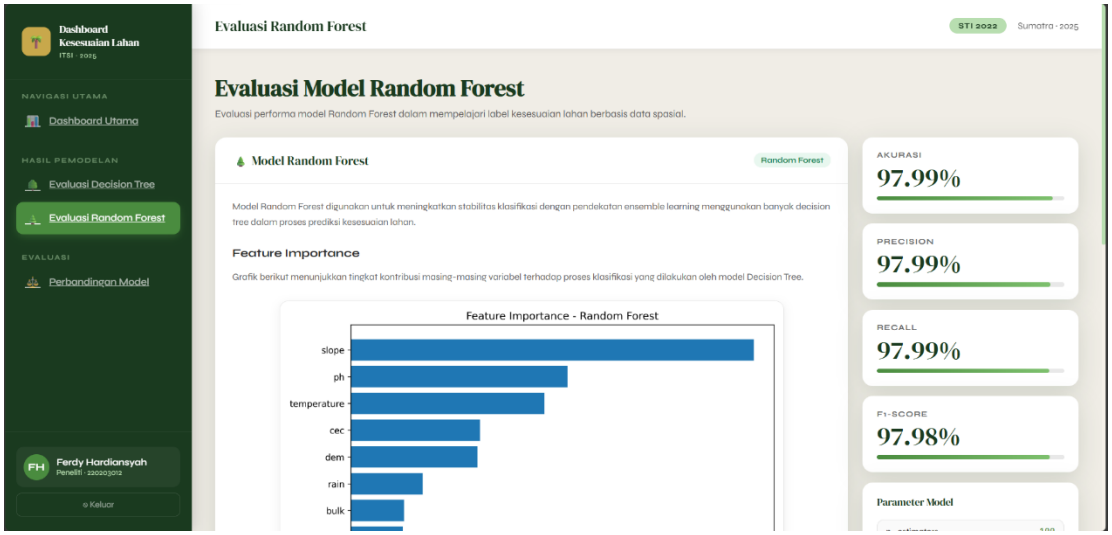
Pada bagian atas halaman ditampilkan informasi ringkasan performa model yang meliputi nilai *accuracy*, *precision*, *recall*, dan *F1-score*. Berdasarkan hasil pengujian, model *Decision Tree* memperoleh nilai *accuracy* sebesar 88,30%, *precision* sebesar 91,62%, *recall* sebesar 88,30%, dan *F1-score* sebesar 89,00%. Selain metrik evaluasi, halaman ini juga menampilkan confusion matrix yang digunakan untuk menggambarkan hasil klasifikasi pada masing-masing kelas kesesuaian lahan. Confusion matrix membantu pengguna dalam mengidentifikasi jumlah data yang berhasil diklasifikasikan dengan benar maupun data yang mengalami kesalahan klasifikasi.

Halaman ini juga menyajikan hasil cross validation yang terdiri dari nilai rata-rata akurasi (CV Mean) sebesar 89,06% dan standar deviasi (CV Std) sebesar 1,09%. Informasi tersebut digunakan untuk menunjukkan tingkat konsistensi model ketika dilakukan pengujian pada beberapa subset data yang berbeda. Selanjutnya, ditampilkan grafik feature importance yang menunjukkan tingkat kontribusi masing-masing variabel terhadap proses pembentukan model *Decision Tree*. Informasi ini membantu pengguna dalam memahami faktor-faktor yang paling berpengaruh terhadap hasil klasifikasi kesesuaian lahan.

Secara keseluruhan, halaman Evaluasi *Decision Tree* berfungsi sebagai sarana visualisasi hasil evaluasi model sehingga pengguna dapat memahami performa model secara lebih mudah dan informatif.

4.8.3 Halaman Evaluasi *Random Forest*

Halaman Evaluasi *Random Forest* digunakan untuk menampilkan hasil evaluasi model *Random Forest* yang dikembangkan dalam penelitian ini. Halaman ini menyediakan informasi mengenai performa model serta faktor-faktor yang memengaruhi proses klasifikasi kesesuaian lahan kelapa sawit di Pulau Sumatra.



Gambar 17 Halaman Evaluasi *Random Forest*

Pada bagian atas halaman ditampilkan ringkasan metrik evaluasi yang terdiri dari *accuracy*, *precision*, *recall*, dan *F1-score*. Berdasarkan hasil pengujian, model *Random Forest* memperoleh nilai *accuracy* sebesar 97,99%, *precision* sebesar 97,99%, *recall* sebesar 97,99%, dan *F1-score* sebesar 97,98%. Nilai tersebut menunjukkan bahwa model memiliki kemampuan yang sangat baik dalam mengklasifikasikan kelas kesesuaian lahan.

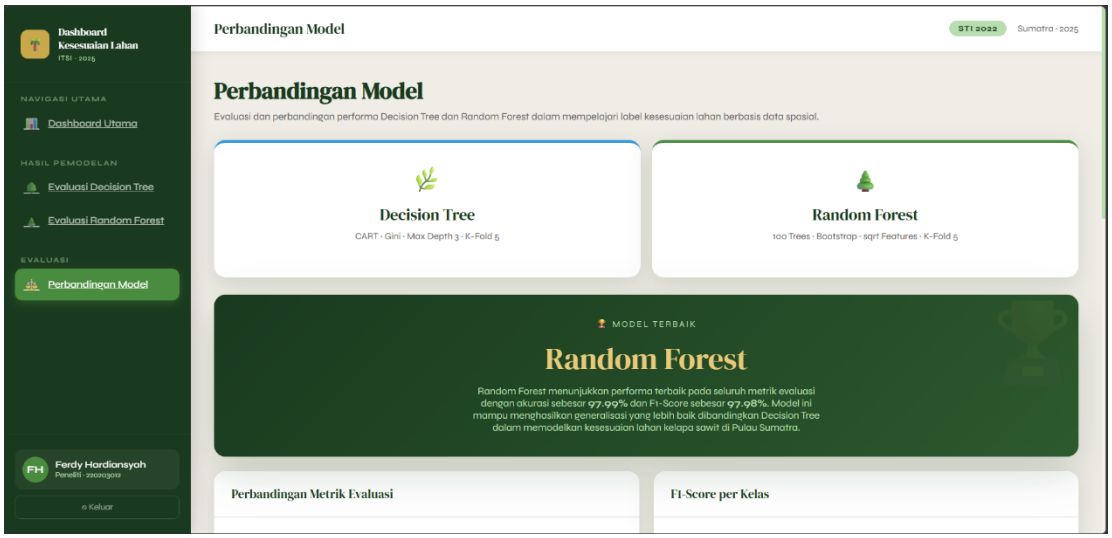
Halaman ini juga menampilkan confusion matrix yang digunakan untuk menggambarkan hasil prediksi model terhadap masing-masing kelas kesesuaian lahan.

Informasi tersebut membantu pengguna dalam mengetahui tingkat keberhasilan klasifikasi serta mengidentifikasi kemungkinan kesalahan prediksi yang masih terjadi pada beberapa kelas. Selain itu, ditampilkan hasil *K-Fold Cross Validation* yang menunjukkan tingkat konsistensi model. Berdasarkan hasil pengujian, *Random Forest* memperoleh nilai CV Mean sebesar 98,57% dengan CV Std sebesar 0,45%. Nilai standar deviasi yang relatif kecil menunjukkan bahwa model memiliki tingkat stabilitas yang baik ketika diuji pada subset data yang berbeda.

Pada bagian feature importance ditampilkan kontribusi masing-masing variabel terhadap proses klasifikasi. Hasil analisis menunjukkan bahwa variabel *slope* merupakan faktor yang paling berpengaruh, diikuti oleh pH tanah, temperature, CEC, dan elevasi (DEM). Informasi ini membantu pengguna dalam memahami faktor biofisik yang paling menentukan tingkat kesesuaian lahan kelapa sawit. Secara keseluruhan, halaman Evaluasi *Random Forest* berfungsi sebagai sarana visualisasi hasil evaluasi model sekaligus memberikan informasi mengenai faktor-faktor utama yang memengaruhi proses klasifikasi kesesuaian lahan.

4.8.4 Halaman Perbandingan Model

Halaman Perbandingan Model digunakan untuk membandingkan performa algoritma *Decision Tree* dan *Random Forest* berdasarkan hasil evaluasi yang diperoleh selama penelitian. Halaman ini dirancang untuk memudahkan pengguna dalam mengidentifikasi model yang memiliki performa terbaik dalam klasifikasi kesesuaian lahan kelapa sawit.



Gambar 18 Halaman Perbandingan Model

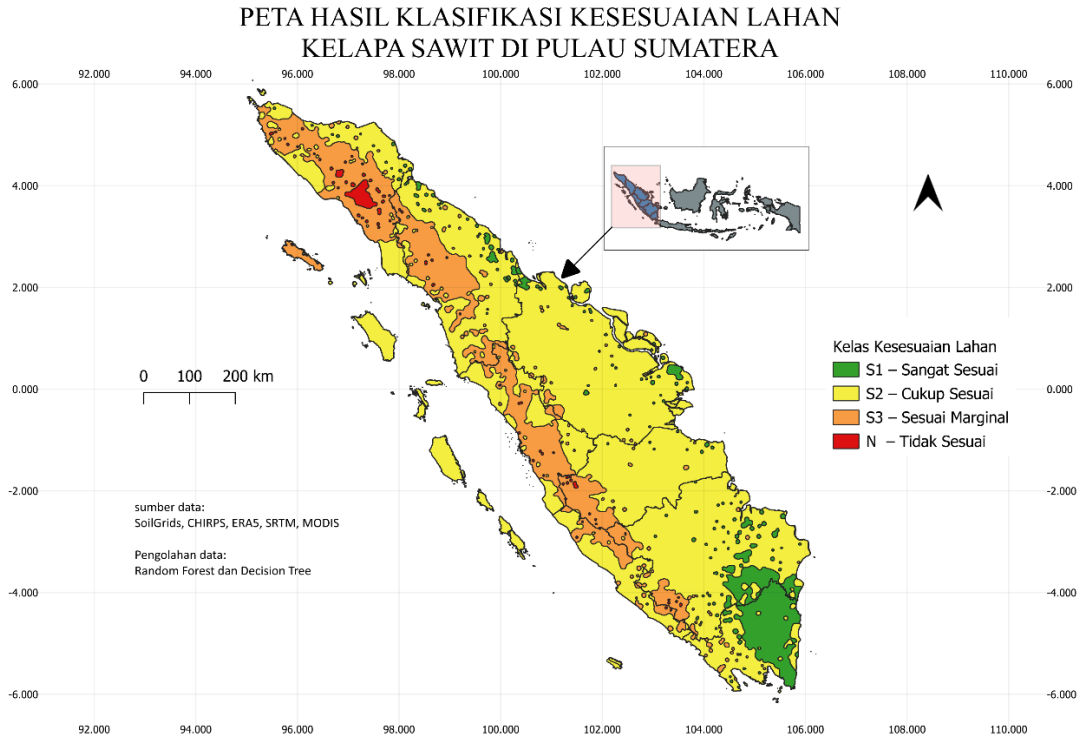
Pada halaman ini ditampilkan perbandingan nilai *accuracy*, *precision*, *recall*, dan *F1-score* antara kedua model. Hasil evaluasi menunjukkan bahwa *Random Forest* memperoleh nilai *accuracy* sebesar 97,99%, sedangkan *Decision Tree* memperoleh nilai *accuracy* sebesar 88,30%. Hasil tersebut menunjukkan bahwa *Random Forest* memiliki performa yang lebih baik dalam melakukan klasifikasi data kesesuaian lahan. Selain metrik evaluasi utama, halaman ini juga menyajikan hasil *K-Fold Cross Validation* untuk kedua model. *Decision Tree* memperoleh nilai CV Mean sebesar 89,06% dengan CV Std sebesar 1,09%, sedangkan *Random Forest* memperoleh nilai CV Mean sebesar 98,57% dengan CV Std sebesar 0,45%. Hasil tersebut menunjukkan bahwa *Random Forest* tidak hanya memiliki akurasi yang lebih tinggi, tetapi juga tingkat stabilitas yang lebih baik dibandingkan *Decision Tree*.

Halaman perbandingan juga dilengkapi dengan visualisasi grafik yang memudahkan pengguna dalam melihat perbedaan performa kedua model secara langsung. Penyajian informasi dalam bentuk grafik membantu proses interpretasi hasil dan memudahkan pengguna dalam menentukan model yang paling sesuai untuk digunakan. Berdasarkan seluruh metrik evaluasi yang ditampilkan, *Random Forest* dipilih sebagai model terbaik dalam penelitian ini karena mampu menghasilkan tingkat

akurasi yang lebih tinggi, kesalahan klasifikasi yang lebih rendah, serta performa yang lebih konsisten dibandingkan *Decision Tree*.

4.9 Visualisasi Spasial Kesesuaian Lahan

Hasil klasifikasi kesesuaian lahan divisualisasikan dalam bentuk peta kesesuaian lahan Pulau Sumatera. Berdasarkan hasil visualisasi, terlihat bahwa kelas S2 mendominasi sebagian besar wilayah penelitian. Sebaran kelas ini menunjukkan bahwa sebagian besar wilayah memiliki kondisi yang cukup sesuai untuk pengembangan kelapa sawit, namun masih memiliki beberapa faktor pembatas.



Gambar 19 Peta Kesesuaian Lahan Kelapa Sawit

Berdasarkan hasil visualisasi spasial pada Gambar 13, kelas S2 (cukup sesuai) mendominasi sebagian besar wilayah penelitian. Sebaran kelas ini menunjukkan bahwa sebagian besar wilayah Pulau Sumatra memiliki kondisi yang cukup mendukung untuk pengembangan kelapa sawit, meskipun masih terdapat beberapa faktor pembatas

biofisik. Kelas S1 (sangat sesuai) umumnya ditemukan pada wilayah dengan kondisi topografi relatif landai, pH tanah yang sesuai, serta kondisi iklim yang mendukung pertumbuhan tanaman kelapa sawit. Sementara itu, kelas S3 (sesuai marginal) dan N (tidak sesuai) cenderung tersebar pada wilayah dengan topografi lebih curam maupun kondisi tanah yang kurang optimal.

Tabel 14 Sebaran Kelas Kesesuaian Lahan Kelapa Sawit di Pulau Sumatra

Kelas	Kategori	Wilayah Dominan
S1	Sangat Sesuai	Lampung bagian selatan, sebagian Sumatera Selatan, dan beberapa wilayah pesisir timur Sumatra
S2	Cukup Sesuai	Riau, Jambi, sebagian Sumatera Utara, dan wilayah dataran rendah Sumatra
S3	Sesuai Marginal	Wilayah Bukit Barisan, Sumatera Barat, Bengkulu, dan daerah dengan lereng sedang
N	Tidak Sesuai	Area pegunungan curam di Aceh dan wilayah dengan keterbatasan biofisik tinggi

Berdasarkan Tabel 9, kelas S2 menjadi kelas yang paling dominan pada wilayah penelitian. Hal ini menunjukkan bahwa sebagian besar wilayah Pulau Sumatra memiliki karakteristik biofisik yang cukup sesuai untuk budidaya kelapa sawit. Sebaliknya, wilayah yang berada pada kawasan pegunungan dan lereng curam cenderung masuk ke dalam kelas S3 dan N karena memiliki faktor pembatas seperti kemiringan lereng yang tinggi dan kondisi tanah yang kurang mendukung. Hasil distribusi spasial tersebut menunjukkan bahwa faktor topografi, curah hujan, dan kondisi tanah memiliki pengaruh yang signifikan terhadap tingkat kesesuaian lahan kelapa sawit di Pulau Sumatra.

4.10 Keterbatasan Penelitian

Random Forest mampu menghasilkan performa yang lebih baik karena menggunakan pendekatan ensemble learning yang menggabungkan banyak pohon keputusan (*Decision Tree*) dalam proses klasifikasi. Pendekatan ini mampu mengurangi overfitting serta meningkatkan kemampuan generalisasi model terhadap data baru sehingga menghasilkan prediksi yang lebih stabil dibandingkan model *Decision Tree* tunggal.

Penelitian ini masih menggunakan pendekatan *rule-based classification* sebagai dasar pembentukan label kesesuaian lahan sehingga kualitas model sangat dipengaruhi oleh akurasi aturan FAO dan BBSDLP yang digunakan. Selain itu, jumlah sampel yang digunakan merupakan hasil ekstraksi titik representatif sehingga belum sepenuhnya merepresentasikan seluruh variasi kondisi biofisik di Pulau Sumatra. Validasi lapangan juga belum dilakukan sehingga hasil penelitian masih memerlukan verifikasi lebih lanjut pada kondisi aktual di lapangan.

BAB V
KESIMPULAN DAN SARAN

5.1 Kesimpulan

Berdasarkan hasil penelitian yang telah dilakukan, dapat disimpulkan bahwa metode *Machine Learning* menggunakan algoritma *Decision Tree* dan *Random Forest* mampu digunakan untuk memprediksi kesesuaian lahan kelapa sawit di Pulau Sumatera dengan performa yang sangat baik. Proses penelitian diawali dengan pengolahan data spasial berupa variabel biofisik yang terdiri dari topografi, tanah, iklim, dan tutupan lahan. Seluruh variabel kemudian diintegrasikan ke dalam dataset tabular melalui proses ekstraksi raster dan analisis spasial. Penentuan kelas kesesuaian lahan dilakukan menggunakan pendekatan *limiting factor* berdasarkan kriteria FAO dan BBSDLP sehingga menghasilkan empat kelas kesesuaian lahan, yaitu S1 (sangat sesuai), S2 (cukup sesuai), S3 (sesuai marginal), dan N (tidak sesuai).

Hasil klasifikasi menunjukkan bahwa kelas S2 (cukup sesuai) mendominasi wilayah penelitian dengan jumlah 1.664 data, diikuti kelas S3 sebanyak 501 data, kelas S1 sebanyak 397 data, dan kelas N sebanyak 170 data. Hasil tersebut menunjukkan bahwa sebagian besar wilayah di Pulau Sumatera memiliki kondisi yang cukup sesuai untuk pengembangan kelapa sawit, meskipun masih terdapat beberapa faktor pembatas. Berdasarkan hasil pemodelan *Machine Learning*, algoritma *Decision Tree* menghasilkan *accuracy* sebesar 88,30%, sedangkan *Random Forest* menghasilkan *accuracy* sebesar 97,99%. Hasil evaluasi menggunakan *K-Fold Cross Validation* menunjukkan nilai rata-rata *accuracy* sebesar 89,06% untuk *Decision Tree* dengan standar deviasi 1,09%, sedangkan *Random Forest* memperoleh rata-rata *accuracy* sebesar 98,57% dengan standar deviasi 0,45%. Nilai standar deviasi yang relatif kecil menunjukkan bahwa kedua model memiliki performa yang stabil, namun *Random Forest* menunjukkan tingkat kestabilan yang lebih tinggi. Hasil tersebut menunjukkan

bahwa *Random Forest* memberikan performa yang lebih baik dibandingkan *Decision Tree* dalam klasifikasi kesesuaian lahan kelapa sawit.

Hasil penelitian juga menunjukkan bahwa algoritma *Random Forest* memiliki performa yang lebih baik dibandingkan *Decision Tree* dalam melakukan klasifikasi kesesuaian lahan kelapa sawit. Hal ini disebabkan karena *Random Forest* menggunakan pendekatan ensemble learning yang mampu meningkatkan stabilitas model dan mengurangi kesalahan klasifikasi. Berdasarkan analisis feature importance, variabel *slope* menjadi faktor paling berpengaruh dengan nilai importance sebesar 0,305, diikuti oleh pH tanah (0,164), temperatur (0,147), kapasitas tukar kation/CEC (0,098), dan elevasi/DEM (0,096). Hasil tersebut menunjukkan bahwa faktor topografi dan kondisi tanah memiliki pengaruh yang besar terhadap tingkat kesesuaian lahan kelapa sawit di wilayah penelitian. Secara keseluruhan, penelitian ini menunjukkan bahwa integrasi Sistem Informasi Geografis (SIG) dan *Machine Learning* dapat digunakan secara efektif dalam mendukung analisis dan pemetaan kesesuaian lahan kelapa sawit.

5.2 Saran

Berdasarkan hasil penelitian yang telah dilakukan, terdapat beberapa saran yang dapat diberikan untuk pengembangan penelitian selanjutnya, yaitu:

1. Penelitian selanjutnya dapat menggunakan jumlah variabel biofisik yang lebih banyak agar model dapat mempelajari karakteristik lahan secara lebih detail.
2. Penelitian berikutnya dapat menggunakan algoritma *Machine Learning* lain seperti XGBoost, *Support* Vector Machine (SVM), maupun Deep Learning untuk membandingkan performa model klasifikasi kesesuaian lahan.
3. Penggunaan data dengan resolusi spasial yang lebih tinggi diharapkan dapat meningkatkan ketelitian hasil pemetaan kesesuaian lahan.

4. Pengembangan sistem berbasis web yang lebih interaktif dengan integrasi peta GIS secara realtime dapat dilakukan untuk meningkatkan kemudahan visualisasi dan pemanfaatan hasil penelitian.
5. Penelitian selanjutnya dapat melakukan validasi lapangan secara langsung untuk meningkatkan akurasi dan keandalan hasil klasifikasi kesesuaian lahan.

DAFTAR PUSTAKA

AbdelRahman, M. A. E., Saleh, A. M., & Arafat, S. M. (2022). *Assessment of land suitability using a soil-indicator-based approach in a geomatics environment*. *Scientific Reports*, *12*(1). https://doi.org/10.1038/s41598-022-22727-7

Abubakar, A., Ishak, M. Y., Abu Bakar, A., Uddin, M. K., & Umar, N. K. (2023). *Geospatial mapping and biophysical analysis of factors that affect oil palm (Elaeis guineensis) yields in Peninsular Malaysia*. *Journal of Agrometeorology*, *25*(1), 128–133. https://doi.org/10.54386/jam.v25i1.1871

Abubakar, A., Ishak, M. Y., Aisyah, A. B., Uddin, M. K., & Ahmad, M. H. (2022). *Assessing the Suitability of Oil Palm (Elaeis guineensis) Production in Peninsular Malaysia based on Soil, Climate and Land Use. Nature Environment and Pollution Technology*, *21*(5), 2141–2163. https://doi.org/10.46488/NEPT.2022.v21i05.010

Abubakar, A., Ishak, M. Y., Bakar, A. A., Uddin, M. K., Ahmad, M. H., Seman, I. A., Ching, L. M., Ahmad, A., & Hashim, Z. (2023). *Geospatial simulation and mapping of climate suitability for oil palm (Elaeis guineensis) production in Peninsular Malaysia using GIS/remote sensing techniques and analytic hierarchy process. Modeling Earth Systems and Environment*, *9*(1), 73–96. https://doi.org/10.1007/s40808-022-01465-9

Ahuchaogu udo Emmanuel U, Ojinnaka O. C, A. C. Chukwuocha, Baywood C. N, & Njoku R. E. (2020). *GIS Based Assessment and Analysis of Land Scape and Terrain Variables in Delta State*. *American Journal of Geographic Information System*. https://doi.org/10.5923/j.ajgis.20200902.03

Alraniri, D. (2023). *Evaluation of land suitability for oil palm plantations in gunung tuleh district*. *In West Pasaman Geography Issues, Socio-Economy Commonity on the West Slope of Marapi, and Action Learning* (Vol. 7, Issue 1). Online. http://sjdgge.ppj.unp.ac.id/index.php/Sjdgge

Balai Besar Sumber Daya Lahan Pertanian. (2016). *Petunjuk Teknis Klasifikasi Tanah Nasional. Kementerian Pertanian Republik Indonesia.* Balai Besar Litbang Sumberdaya Lahan Pertanian.

Dwiana Saputri Munika, Agus Nurokhim, Adymas Putro Utomo, & Rina Lesmana. (2024). *Pemetaan sebaran kelas kesesuaian lahan tanaman kelapa sawit (elaeis*

guinensis jacq) di kecamatan tanjung selor, kabupaten bulungan. *2*(1). https://journal.unikaltar.ac.id/index.php/JIPEK

Fulazzaky, T., Saefuddin, A., & Soleh, A. M. (2024). *Evaluating Ensemble Learning Techniques for Class Imbalance in Machine Learning: A Comparative Analysis of Balanced Random Forest, SMOTE-RF, SMOTEBoost, and RUSBoost*. *Scientific Journal of Informatics*, *11*(4), 969–980. https://doi.org/10.15294/sji.v11i4.15937

Gajowniczek, K., & Ząbkowski, T. (2021). *Interactive Decision Tree learning and decision rule extraction based on the imbtreeentropy and imbtreeauc packages. Processes*, *9*(7). https://doi.org/10.3390/pr9071107

Goenadi, D. H., Setyobudi, R. H., Yandri, E., Siregar, K., Winaya, A., Damat, D., Widodo, W., Wahyudi, A., Adinurani, P. G., Mel, M., Zekker, I., Mazwan, M. Z., Siskawardani, D. D., Purbajanti, E. D., & Ekawati, I. (2021). *Land Suitability Assessment and Soil Organic Carbon Stocks as Two Keys for Achieving Sustainability of Oil Palm (Elaeis guineensis Jacq.). Sarhad Journal of Agriculture*, *37*(Special Issue 1), 184–196. https://doi.org/10.17582/journal.sja/2022.37.s1.184.196

Ibrahim, S. (2023). *Improving Land Use/Cover Classification Accuracy from Random Forest Feature Importance Selection Based on Synergistic Use of Sentinel Data and Digital Elevation Model in Agriculturally Dominated Landscape*. *Agriculture (Switzerland)*, *13*(1). https://doi.org/10.3390/agriculture13010098

Ifeanyi, O. B., Nkiru, N. C., & Chiebonam, I. V. (2024). *Geospatial Analysis of Topography, Hydrology, and Land Use Dynamics in Owerri and Environs Region, Southeastern Nigeria*. *International Journal of Recent Engineering Science*, *11*(4), 97–112. https://doi.org/10.14445/23497157/ijres-v11i4p113

Li, A., Zhang, Z., Hong, Z., Liu, L., Liu, L., Ashraf, T., & Liu, Y. (2024). *Spatial suitability evaluation based on multisource data and Random Forest algorithm: a case study of Yulin, China. Frontiers in Environmental Science*, *12*. https://doi.org/10.3389/fenvs.2024.1338931

Ma, S., & Zhai, J. (2023). *Big data Decision Tree for continuous-valued attributes based on unbalanced cut points. Journal of Big Data*, *10*(1). https://doi.org/10.1186/s40537-023-00816-2

Mgohele, R. N., Massawe, B. H. J., Shitindi, M. J., Sanga, H. G., & Omar, M. M. (2025). *Land suitability assessment for sisal production: A Machine Learning and*

Analytical Hierarchy Process integrated approach. Soil Advances, *3*, 100048. https://doi.org/10.1016/j.soilad.2025.100048

Moisa, M. B., Feyissa, M. E., Dejene, I. N., Tiye, F. S., Deribew, K. T., Roba, Z. R., Gurmessa, M. M., & Gemeda, D. O. (2023). *Evaluation of land suitability for Moringa Oleifera tree cultivation by using Geospatial technology: The case of Dhidhessa Catchment, Abay Basin, Ethiopia. Oil Crop Science*, *8*(1), 45–55. https://doi.org/10.1016/j.ocsci.2023.02.007

Mushagalusa, C. A., Fandohan, A. B., & Glèlè Kakaï, R. (2024). *Random Forest and spatial cross-validation performance in predicting species abundance distributions. Environmental Systems Research*, *13*(1). https://doi.org/10.1186/s40068-024-00352-9

Nabiollahi, K., Kebonye, N. M., Molani, F., Tahari-Mehrjardi, M. H., Taghizadeh-Mehrjardi, R., Shokati, H., & Scholten, T. (2024). *Assessment of Land Suitability Potential Using Ensemble Approaches of Advanced Multi-Criteria Decision Models and Machine Learning for Wheat Cultivation. Remote Sensing*, *16*(14). https://doi.org/10.3390/rs16142566

Nangoy Fransiska, & Widianto Stanley. (2025, December 4). *Indonesia pledges action on companies causing catastrophic Sumatra floods*. Reuters. https://www.reuters.com/sustainability/climate-energy/indonesia-promises-action-any-mining-permit-violations-sumatra-floods-toll-about-2025-12-04/

Nuti, G., Jiménez Rugama, L. A., & Cross, A. I. (2021). *An Explainable Bayesian Decision Tree Algorithm. Frontiers in Applied Mathematics and Statistics*, *7*. https://doi.org/10.3389/fams.2021.598833

Oktavianti, E., Agustin, M., & Sari, R. (2023). *Implementasi algoritma Decision Tree dengan fitur seleksi weight by information gain* (Vol. 9, Issue 2).

Pradana, A. N., Djuraidah, A., & Soleh, A. M. (2023). *Land Use Change Modelling Using Logistic Regression, Random Forest and Additive Logistic Regression in Kubu Raya Regency, West Kalimantan. Forum Geografi*, *37*(2), 149–163. https://doi.org/10.23917/forgeo.v37i2.23270

Prasetiyowati, M. I., Maulidevi, N. U., & Surendro, K. (2021). *Determining threshold value on information gain feature selection to increase speed and prediction accuracy of Random Forest. Journal of Big Data*, *8*(1). https://doi.org/10.1186/s40537-021-00472-4

Putra, A. N., Jaenudin, Prasetya, N. R., Sugiarto, M. T., Sudarto, Prayogo, C., Maritimo, F., & Admajaya, F. T. (2025). *Utilizing Remote Sensing and Random*

Forests to Identify Optimal Land Use Scenarios and Address the Increase in Landslide Susceptibility. Sustainability (Switzerland), *17*(9). https://doi.org/10.3390/su17094227

Putra, A. N., Ustiatik, R., Prasetya, N. R., Adara, E. A., Nita, I., Hadi, S. R. I., Soemarno, Sudarto, Utami, S. R., Munir, M., & Rayes, M. L. (2025). *New Emerging and Comprehensive Land Mapping Unit at Detailed Scale: Integrating Random Forest Analysis and Remote Sensing Techniques for Sustainable Land Management. Caraka Tani: Journal of Sustainable Agriculture*, *40*(3), 307–325. https://doi.org/10.20961/carakatani.v40i3.97530

Putu Raditia Satriawan, Gusti Michael Ferdinand, Nyoman Putra Satya Natha, I Gst Ayu Pradnya Saci Devi Sastrawan, Ni Wayan Marti, & Ni Putu Novita Puspa Dewi. (2024). *Evaluasi dan perbandingan algoritma klasifikasi dalam analisis penggunaan lahan dengan teknologi remote sensing: sebuah kajian sistematik*. *Information System and Emerging Technology Journal, Vol. 5, No. 2*.

Radočaj, D., & Jurišić, M. (2022). *GIS-Based Cropland Suitability Prediction Using Machine Learning: A Novel Approach to Sustainable Agricultural Production. In Agronomy* (Vol. 12, Issue 9). MDPI. https://doi.org/10.3390/agronomy12092210

Rendana, M., Rahim, S. A., Idris, W. M. R., Rahman, Z. A., & Lihan, T. (2022). *Agricultural Land Evaluation Using GIS-Based Matching Method in Highland Areas for Oil Palm Cultivation. Caraka Tani: Journal of Sustainable Agriculture*, *37*(1), 100–110. https://doi.org/10.20961/carakatani.v37i1.57441

Sathiyamurthi, S., Subbarayan, S., Ramya, M., Sivasakthi, M., Gobi, R., Qaysi, S., Praveen Kumar, S., Lee, J., Alarifi, N., Wahba, M., & M. Youssef, Y. (2024). *Advancing Agricultural Land Suitability in Urbanized Semi-Arid Environments: Insights from Geospatial and Machine Learning Approaches*. *ISPRS International Journal of Geo-Information*, *13*(12). https://doi.org/10.3390/ijgi13120436

BIOGRAFI PENULIS



Ferdy Hardiansyah lahir di Sinah Kasih Dusun 2 pada tanggal 25 Agustus 2004. Penulis menyelesaikan pendidikan dasar di SD Negeri 102027 Sei Rampah, pendidikan menengah pertama di SMP Negeri 4 Sei Rampah, dan pendidikan menengah atas di SMA Swasta Teladan Sei Rampah. Pada tahun 2022, penulis melanjutkan pendidikan tinggi di Institut Teknologi Sawit Indonesia pada Program Studi Sistem dan Teknologi Informasi.

Selama menempuh pendidikan di perguruan tinggi, penulis aktif dalam organisasi kemahasiswaan, yaitu Himpunan Mahasiswa Jurusan Sistem dan Teknologi Informasi (HMJ STI). Selain itu, penulis juga melaksanakan Praktik Kerja Lapangan (PKL) di PTPN IV Padang Matinggi sebagai bagian dari proses pembelajaran dan pengembangan kompetensi di bidang teknologi informasi dan perkebunan.

Penulis memiliki minat yang besar pada bidang *Machine Learning* dan *Geographic Information System* (GIS), khususnya dalam penerapannya untuk mendukung pengambilan keputusan pada sektor perkebunan kelapa sawit. Sebagai tugas akhir untuk memperoleh gelar Sarjana Komputer, penulis menyusun skripsi yang berjudul "Perbandingan Model *Decision Tree* dan *Random Forest* dalam Memprediksi Kesesuaian Lahan Tanaman Kelapa Sawit". Penelitian ini berfokus pada perbandingan kinerja algoritma *Decision Tree* dan *Random Forest* dalam memprediksi tingkat kesesuaian lahan kelapa sawit dengan memanfaatkan data spasial dan pendekatan *Machine Learning*.

Di luar kegiatan akademik, penulis memiliki hobi bernyanyi, bermain gitar, bermain voli, futsal, dan lari. Dengan bekal pendidikan, pengalaman organisasi, dan penelitian yang telah dilakukan, penulis berharap dapat terus mengembangkan kemampuan di bidang teknologi informasi, analisis data, serta sistem pendukung keputusan yang bermanfaat bagi masyarakat dan industri perkebunan Indonesia.